



CIPMA – UNESCO CHAIRE

Université d'Abomey-Calavi

Chaire Internationale en Physique Mathématique et Applications
(CIPMA – Chaire UNESCO)

Master of Science en Statistique Appliquée au Vivant

Analyse et Modélisation du Risque d'Insécurité Alimentaire des Ménages au Bénin



Présenté par :

DAHOUI Pinel Baudelaire T.

Directeur de mémoire :

Dr. Nicodème ATCHADE

Abomey calavi, République du Bénin

Année académique : 2025–2026

Table des matières

1	Introduction	1
2	Problématique	3
2.1	État des lieux approfondi de l'insécurité alimentaire au Bénin	3
2.2	Lacunes dans la littérature : le <i>Research Gap</i>	4
2.2.1	Ce qui existe dans la littérature mondiale	4
2.2.2	Ce qui existe pour l'Afrique subsaharienne	5
2.2.3	Ce qui existe spécifiquement pour le Bénin	5
2.2.4	Synthèse : la quadruple lacune à combler	6
2.3	Questions de recherche spécifiques	6
2.4	Objectif général et objectifs spécifiques	6
2.4.1	Objectif général	6
2.4.2	Objectifs spécifiques	7
2.5	Hypothèses de recherche	7
2.6	Intérêt et but de la recherche	8
2.6.1	Intérêt scientifique	8
2.6.2	Intérêt opérationnel	8
2.6.3	Intérêt pour les politiques publiques	9
2.6.4	But de la recherche	9
2.7	Tableau de cohérence interne du cadre de recherche	10
3	Revue de littérature	11
3.1	Évolution conceptuelle de la sécurité alimentaire	11
3.1.1	De la disponibilité agrégée à l'accès individuel : une révolution paradigmatique	11
3.1.2	La consolidation dans les années 1990–2000 : les quatre piliers .	12
3.1.3	La complexité contemporaine : vers un cadre hexadimensionnel .	12
3.2	Mesure de la sécurité alimentaire : indicateurs, forces et limites	13
3.2.1	Le Score de Consommation Alimentaire : atouts et limites docu- mentées	13
3.2.2	Autres indicateurs : HFIAS, <i>rCSI</i> et CARI	14
3.3	Les déterminants de la sécurité alimentaire des ménages : revue empirique	15
3.3.1	Cadres analytiques structurants	15
3.3.2	Capital humain : éducation, genre et composition du ménage . .	15
3.3.3	Capital économique et financier : pauvreté, revenus et diversification	16
3.3.4	Capital naturel : accès à la terre, bétail et ressources environne- mentales	16

3.3.5	Capital physique et localisation : infrastructures et milieu de résidence	17
3.3.6	Capital social et politiques publiques	17
3.4	Modélisation économétrique du risque alimentaire : approches classiques	18
3.4.1	La régression logistique binaire : modèle canonique et limites . .	18
3.5	Modélisation par machine learning du risque alimentaire	18
3.5.1	Pertinence et avantages comparatifs du machine learning	18
3.5.2	Random Forest : principe, performances et applications en sécurité alimentaire	19
3.5.3	XGBoost : optimisation avancée et état de l'art prédictif	19
3.5.4	Interprétabilité des modèles ML : des importances classiques aux valeurs SHAP	20
3.6	Calibration des modèles de classification	22
3.7	Cartographie de la vulnérabilité alimentaire	22
3.8	Synthèse de la revue de littérature et positionnement du présent travail	23
4	Matériel et Méthodologie	25
4.1	Source de données : l'enquête AGVSAN Bénin 2017	25
4.1.1	Présentation et justification du choix des données	25
4.1.2	Plan de sondage et représentativité	26
4.2	Construction de la variable dépendante	27
4.2.1	Choix de l'indicateur de sécurité alimentaire : utilisation de la classification officielle déjà disponible	27
4.2.2	Modalités de la variable Round_INDICE_SECAL et dichotomisation	28
4.2.3	Score de Consommation Alimentaire (SCA) : rappel méthodologique et rôle de validation croisée	29
4.2.4	Analyse de sensibilité et validation croisée	30
4.2.5	Indicateurs complémentaires de validation	30
4.3	Variables indépendantes extraites du questionnaire	31
4.3.1	Capital humain (Section 1 – Démographie et éducation)	31
4.3.2	Capital physique et habitat (Section 3)	32
4.3.3	Capital financier et économique (Sections 5 et 6)	33
4.3.4	Capital naturel et agricole (Sections 7 et 8)	34
4.3.5	Capital social et chocs (Sections 9 et 10)	35
4.3.6	Tableau récapitulatif des variables retenues pour la modélisation	36
4.4	Analyse descriptive et tests statistiques pré-estimation	38
4.4.1	Variables focales et nature statistique	38
4.4.2	Analyse univariée	38
4.4.3	Test de normalité des variables continues	40

4.4.4	Analyse bivariée : croisement de chaque variable focale avec la variable dépendante	40
4.4.5	Détection de la multicolinéarité	42
4.4.6	Gestion des données manquantes	43
4.5	Modélisation économétrique et prédictive	43
4.5.1	Partition stratifiée de l'échantillon	43
4.5.2	Gestion du déséquilibre de classes	44
4.5.3	Modèle 1 : Régression Logistique Binaire	44
4.5.4	Modèle 2 : Random Forest	48
4.5.5	Modèle 3 : XGBoost (<i>eXtreme Gradient Boosting</i>)	49
4.6	Validation croisée par grappes	51
4.7	Interprétabilité des modèles : valeurs SHAP	52
4.7.1	Principe et calcul des valeurs SHAP	52
4.7.2	Visualisations SHAP produites	52
4.8	Évaluation, calibration et comparaison des modèles	53
4.8.1	Métriques de performance	53
4.8.2	Évaluation de la calibration	54
4.8.3	Critères de sélection du meilleur modèle	54
4.9	Cartographie prédictive du risque d'insécurité alimentaire	55
4.9.1	Probabilités individuelles prédites	55
4.9.2	Agrégation spatiale pondérée à l'échelle communale	55
4.9.3	Test d'autocorrélation spatiale (indice de Moran)	55
4.9.4	Discrétisation du risque et cartographie choroplèthe	56
4.10	Logiciels et packages utilisés	56
4.10.1	Reproductibilité logicielle	57
4.11	Considérations éthiques	57
	Références bibliographiques	59

1 Introduction

À l'aube du troisième millénaire, la communauté internationale s'était fixé comme objectif global de faire le nécessaire pour éradiquer la faim dans le monde à l'horizon 2030, en inscrivant cet impératif au cœur de l'Objectif de Développement Durable numéro 2. Or, l'état des lieux dressé par les organisations onusiennes révèle une réalité préoccupante : selon le rapport conjoint de la FAO, du PAM, du FIDA, de l'OMS et de l'UNICEF, entre 691 et 783 millions de personnes dans le monde étaient confrontées à la faim en 2022, soit une augmentation de près de 122 millions par rapport à la période prépandémique de 2019 [28]. Mais il faut noter que l'Afrique subsaharienne concentre une part disproportionnée de cette détresse alimentaire : cette région accueille plus de 282 millions de personnes en situation d'insécurité alimentaire, représentant ainsi la prévalence la plus élevée parmi toutes les régions du globe [28]. Dans ce tableau sombre, l'Afrique de l'Ouest se distingue par la vulnérabilité structurelle de ses systèmes agro-alimentaires, exposés aux aléas climatiques, à l'instabilité des marchés céréaliers et à des dynamiques démographiques particulièrement soutenues [77].

Au Bénin, le paradoxe alimentaire est saisissant. D'un côté, l'agriculture constitue le socle de l'économie nationale, contribuant à hauteur de 22 à 26 % au Produit Intérieur Brut et occupant plus de 70 % de la population active [39]. De l'autre, les données les plus récentes de l'Analyse Globale de la Vulnérabilité, de la Sécurité Alimentaire et Nutritionnelle (AGVSAN) révèlent qu'une proportion non négligeable des ménages béninois demeure en situation d'insécurité alimentaire, avec des disparités géographiques marquées entre les départements septentrionaux notamment l'Alibori, l'Atacora et la Donga où les taux de vulnérabilité atteignent des niveaux critiques, et les régions méridionales, structurellement mieux intégrées aux marchés [62]. La malnutrition chronique, particulièrement chez les enfants de moins de cinq ans, constitue une manifestation emblématique de l'échec de la sécurité alimentaire à se traduire concrètement en bien-être nutritionnel [75].

Face à ces constats, une approche purement descriptive de la sécurité alimentaire se limitant à mesurer la prévalence de l'insécurité dans la population présente une portée opérationnelle limitée pour les décideurs et les acteurs humanitaires. Le passage d'une *logique descriptive* à une *logique d'aide à la décision proactive* constitue un enjeu scientifique de premier ordre. Il s'agit de modéliser statistiquement le risque d'insécurité alimentaire de chaque ménage à partir de ses caractéristiques observables, puis de spatialiser ces prédictions pour identifier, avec une précision géographique fine, les poches de vulnérabilité sur le territoire béninois. Cette démarche prédictive et cartographique permet de fonder le ciblage des interventions subventions alimentaires, filets sociaux, programmes d'appui à la production sur une base empirique robuste, en

optimisant l'allocation de ressources toujours insuffisantes [5].

C'est précisément à cette démarche : analytique, prédictive et cartographique que répond la question centrale de recherche qui structure le présent mémoire :

Quels sont les déterminants socio-économiques et démographiques du risque d'insécurité alimentaire des ménages béninois et dans quelle mesure ces déterminants permettent-ils de construire un modèle prédictif fiable du statut alimentaire individuel ?

La présente étude s'articule autour de sept parties principales : une problématique présentant les *limites* identifiées dans la littérature (Section 2) ; une revue de littérature portant sur l'évolution conceptuelle de la sécurité alimentaire, ses déterminants et les approches de modélisation (Section 3) ; une méthodologie décrivant rigoureusement les sources de données, les tests statistiques et l'analyse comparative des modèles ainsi que leur procédure d'évaluation comparative (Section 4) ; enfin, les résultats (Section 5) ; la discussion (Section 6) ; et la conclusion avec les recommandations (Section 7) viendront clore le présent travail.

2 Problématique

Dans la présente section, nous allons approfondir l'état des lieux de l'insécurité alimentaire au Bénin, identifier les lacunes de la littérature existante (research gap) en la structurant en trois niveaux, formuler les questions de recherche spécifiques, énoncer l'objectif général, ensuite spécifiques, et poser enfin les hypothèses testables associées à chaque objectif, dont la cohérence interne sera résumée dans un tableau synoptique.

2.1 État des lieux approfondi de l'insécurité alimentaire au Bénin

D'entrée de jeu, la sécurité alimentaire au Bénin se caractérise par une dualité structurelle profonde entre les zones de relative abondance agricole et des territoires chroniquement déficitaires. En effet, selon les données de l'Analyse Globale de la Vulnérabilité et de la Sécurité Alimentaire (AGVSAN 2017), enquête la plus récente et la plus exhaustive réalisée au Bénin sur cette thématique, portant sur 14 952 ménages enquêtés sur l'ensemble du territoire national [62], les résultats révèlent une prévalence de l'insécurité alimentaire de **25,69 % en milieu urbain** et de **74,70 % en milieu rural**. Ces chiffres traduisent un gradient géographique saisissant entre les deux milieux de résidence et placent le Bénin dans une situation de vulnérabilité alimentaire structurelle préoccupante, d'autant plus que le pays reste l'un des principaux exportateurs de coton en Afrique de l'Ouest.

Mais il faut noter que les travaux réalisés dans le cadre des enquêtes AGVSAN distinguent analytiquement deux formes d'insécurité alimentaire qui appellent des réponses politiques différenciées : l'insécurité alimentaire *chronique*, résultant d'une pauvreté profonde et persistante qui empêche les ménages d'accéder durablement à une alimentation suffisante ; et l'insécurité alimentaire *saisonnnière* ou conjoncturelle, qui survient lors des périodes de soudure agricole, lorsque les stocks de la campagne précédente s'épuisent avant que les nouvelles récoltes ne soient disponibles [62]. La soudure agro-pastorale, qui s'étend généralement de juin à septembre dans les régions septentrionales, fragilise de manière cyclique des ménages qui se trouvent en situation d'équilibre précaire durant les mois de bonne saison [39].

Les disparités géographiques sont bien documentées dans la littérature béninoise. En effet, les départements de l'Alibori, de l'Atacora et de la Donga affichent systématiquement des taux d'insécurité alimentaire supérieurs à la moyenne nationale, en raison notamment d'un enclavement géographique qui renchérit l'accès aux marchés, d'une dépendance quasi exclusive à l'agriculture pluviale sans irrigation, et d'une intégration plus faible aux filières commerciales [62]. À l'inverse, les départements de l'Atlantique

et du Littoral bénéficient d'une économie plus diversifiée, d'une meilleure desserte en infrastructures et d'un accès facilité aux denrées importées [3]. Cette géographie de la vulnérabilité alimentaire recouvre en grande partie la géographie de la pauvreté monétaire : selon l'INSAE [39], l'incidence de la pauvreté monétaire est plus de deux fois supérieure en milieu rural qu'en milieu urbain, et les régions nord-est du pays concentrent les taux de pauvreté les plus élevés.

Au-delà de la dimension monétaire, les travaux récents insistent sur la multidimensionalité de la vulnérabilité alimentaire. La pauvreté non monétaire définie par le manque d'accès aux services sociaux de base, à l'eau potable, à l'assainissement et à l'éducation constitue un déterminant structurel de l'insécurité alimentaire qui échappe partiellement aux indicateurs de revenus [1]. La dépendance à une agriculture non diversifiée, le faible accès aux intrants améliorés et la vulnérabilité aux chocs climatiques amplifient les risques pour les ménages les plus précaires [8].

Face à ces constats, une approche purement descriptive de la sécurité alimentaire se limitant à mesurer la prévalence de l'insécurité des populations présente une portée opérationnelle limitée pour les décideurs et les acteurs humanitaires. Le passage d'une *logique descriptive* à une *logique d'aide à la décision proactive* constitue un enjeu scientifique de premier ordre, que la présente étude se propose d'adresser par la modélisation prédictive et la cartographie du risque d'insécurité alimentaire.

2.2 Lacunes dans la littérature : le *Research Gap*

L'identification rigoureuse des lacunes scientifiques existantes nécessite une lecture structurée à trois niveaux : la littérature mondiale, la littérature africaine et subsaharienne, et la littérature spécifiquement béninoise. C'est précisément à l'intersection de ces niveaux que se situe la contribution originale du présent travail.

2.2.1 Ce qui existe dans la littérature mondiale

À l'échelle internationale, la modélisation statistique de la sécurité alimentaire est un champ bien développé. Les approches économétriques classiques régression logistique, modèles probit ont été appliquées dans de nombreux contextes pour identifier les déterminants de l'insécurité alimentaire [24, 37, 55]. Plus récemment, l'essor du *machine learning* a conduit à des applications prometteuses dans la prédiction de la pauvreté et de la vulnérabilité alimentaire, notamment via des algorithmes d'arbres de décision ensemblistes (*Random Forest*, *XGBoost*) capables de capturer des relations non linéaires complexes [10, 12, 15]. Les méthodes modernes d'interprétabilité notamment les valeurs SHAP (*SHapley Additive exPlanations*) développées par Lundberg et Lee [47] permettent désormais de réconcilier la puissance prédictive des algorithmes ML et l'exigence d'interprétabilité propre aux sciences sociales et aux politiques publiques. La

cartographie de la vulnérabilité par agrégation des probabilités prédites à des échelles géographiques fines constitue également un domaine en pleine expansion [2, 40, 61].

2.2.2 Ce qui existe pour l'Afrique subsaharienne

En Afrique subsaharienne, la littérature sur la modélisation de l'insécurité alimentaire s'est principalement développée autour de deux approches. D'un côté, les études économétriques dominantes utilisent des régressions logistiques ou probit pour identifier les déterminants socio-économiques de l'insécurité alimentaire au Nigeria [4, 55], au Kenya, en Éthiopie [24] et en Tanzanie. Ces études produisent des résultats interprétables utiles mais ne sont généralement pas évaluées dans une perspective prédictive rigoureuse via des métriques hors-échantillon standardisées, ce qui rend impossible toute comparaison de leurs performances avec des alternatives algorithmiques. De l'autre, les applications ML restent encore émergentes en Afrique subsaharienne : Browne et al. [12] ont appliqué le *Random Forest* à des données d'enquêtes de 12 pays africains pour prédire simultanément la pauvreté et la malnutrition, obtenant une AUROC de 0,82, significativement supérieure à celle d'une régression logistique de référence (0,74) ; Andrée et al. [2] ont utilisé le *Random Forest* pour prédire les crises alimentaires à 12 mois d'horizon à partir de données de flux d'actualités. Toutefois, ces études africaines partagent des lacunes communes : elles ne procèdent pas à une comparaison systématique et rigoureuse des performances prédictives entre approches économétriques et algorithmes ML sur les mêmes données ; elles n'intègrent pas les méthodes d'interprétabilité modernes (SHAP) ; et elles ne débouchent généralement pas sur une cartographie du risque, ni sur un outil opérationnel d'aide à la prise de décision.

2.2.3 Ce qui existe spécifiquement pour le Bénin

Au Bénin, la littérature académique sur la sécurité alimentaire reste majoritairement descriptive. Les travaux disponibles notamment Azonhiho et al. [3] documentent les disparités géographiques de la vulnérabilité alimentaire et identifient certains déterminants via des analyses bivariées ou des régressions logistiques simples non évaluées dans une perspective prédictive rigoureuse. Les rapports institutionnels du PAM [62] et de l'INSAE [39] fournissent des statistiques descriptives précieuses mais n'entrent pas dans le champ de la modélisation prédictive comparative. À notre connaissance et sur la base de notre revue systématique de la littérature, **aucune étude publiée portant spécifiquement sur le Bénin ne réalise simultanément** : (i) une comparaison systématique des performances prédictives de plusieurs algorithmes ML sur données AGVSAN avec évaluation hors-échantillon rigoureuse ; (ii) une analyse d'interprétabilité via les valeurs SHAP ; (iii) une cartographie communale du risque fondée sur des probabilités prédites par un modèle validé ; (iv) le déploiement opérationnel du modèle dans

un outil d'aide à la prise de décision accessible aux acteurs humanitaires.

2.2.4 Synthèse : la quadruple lacune à combler

Cette lecture structurée à trois niveaux fait apparaître une **quadruple lacune** que le présent mémoire ambitionne de combler :

Lacune 1 : Absence de modélisation prédictive rigoureuse évaluée hors-échantillon sur des données béninoises d'insécurité alimentaire.

Lacune 2 : Absence de comparaison systématique des performances de plusieurs algorithmes (Logit, *Random Forest*, *XGBoost*) sur les mêmes données avec des métriques standardisées (AUROC, *Recall*, *F1-score*, Brier Score).

Lacune 3 : Absence d'analyse d'interprétabilité avancée via les valeurs SHAP, permettant de réconcilier puissance prédictive et lisibilité pour les décideurs politiques et humanitaires.

Lacune 4 : Absence d'un outil opérationnel encapsulant le modèle prédictif pour permettre le ciblage en temps réel des ménages vulnérables hors échantillon.

2.3 Questions de recherche spécifiques

À partir du *research gap* identifié, quatre questions de recherche structurent la démarche analytique :

Question 1 – Déterminants : Quels facteurs socio-démographiques, économiques influencent significativement le risque d'insécurité alimentaire des ménages béninois et dans quel sens agissent-ils ?

Question 2 – Prédiction comparative : Parmi la Régression Logistique, le *Random Forest* et l'*XGBoost*, quel modèle offre la meilleure performance prédictive hors-échantillon pour identifier les ménages à risque ?

Question 3 – Cartographie : Comment spatialiser les probabilités individuelles prédites pour identifier les poches de vulnérabilité géographique à l'échelle communale au Bénin ?

Question 4 – Opérationnalisation : Dans quelle mesure le modèle retenu peut-il être déployé dans un outil d'aide à la prise de décision permettant des prédictions sur des ménages hors échantillon ?

2.4 Objectif général et objectifs spécifiques

2.4.1 Objectif général

Analyser et modéliser le risque d'insécurité alimentaire des ménages béninois en combinant approche économétrique et algorithmes de *machine learning*, afin de produire

un outil de ciblage géographique et socio-économique opérationnel pour les acteurs humanitaires.

2.4.2 Objectifs spécifiques

- OS1 :** Identifier les déterminants socio-économiques et démographiques du risque d'insécurité alimentaire des ménages béninois .
- OS2 :** Comparer les performances prédictives hors-échantillon des modèles de Régression Logistique et Machine learning sur la base de métriques standardisées et de mesures d'interprétabilité SHAP.
- OS3 :** Cartographier le risque prédit d'insécurité alimentaire sur l'ensemble du territoire béninois à partir des probabilités individuelles prédites par le meilleur modèle.
- OS4 :** Développer un outil d'aide à la prise de décision encapsulant le meilleur modèle pour permettre la prédiction du statut alimentaire de ménages hors échantillon et la visualisation dynamique de la cartographie du risque.

La progression logique entre ces quatre objectifs est la suivante : l'identification des déterminants (OS1) fonde la sélection des variables pour la modélisation comparative (OS2) ; les probabilités prédites par le meilleur modèle (OS2) alimentent la cartographie (OS3) ; l'ensemble du pipeline est enfin encapsulé dans l'outil opérationnel (OS4).

2.5 Hypothèses de recherche

- H_1 – **associée à OS1 :** Le niveau d'éducation du chef de ménage, la diversification des revenus, l'accès à l'eau potable et la résidence en milieu rural sont des déterminants statistiquement significatifs de l'insécurité alimentaire des ménages béninois [50, 67].
- H_2 – **associée à OS2 :** Les algorithmes *Random Forest* et *XGBoost* offrent une performance prédictive mesurée par l'AUC et le Brier Score statistiquement supérieure à celle de la Régression Logistique, confirmée par le test de DeLong au seuil de 5 % [10, 15].
- H_3 – **associée à OS3 :** Les probabilités prédites d'insécurité alimentaire présentent une autocorrélation spatiale positive et significative à l'échelle communale, avec des poches de vulnérabilité concentrées dans les départements septentrionaux du Bénin [3, 62].
- H_4 – **associée à OS4 :** Le modèle retenu présente une stabilité et une calibration suffisantes pour produire des prédictions fiables sur des ménages hors échantillon aux profils similaires à ceux de l'enquête AGVSAN 2017.

2.6 Intérêt et but de la recherche

La présente étude revêt un intérêt à la fois **scientifique**, **opérationnel** et **politique**, que nous détaillons successivement.

2.6.1 Intérêt scientifique

Sur le plan scientifique, ce travail présente un intérêt à trois niveaux.

Au niveau méthodologique, la présente étude contribue au développement des méthodes d'analyse de la sécurité alimentaire en Afrique subsaharienne en proposant une démarche de modélisation prédictive comparative rigoureuse, articulant approches économétriques classiques et algorithmes de *machine learning* sur des données d'enquête à plan de sondage complexe. La prise en compte explicite de la structure du plan de sondage dans la validation croisée via la procédure de validation croisée *K-fold* par grappes et dans l'entraînement des algorithmes ML constitue une innovation méthodologique par rapport aux travaux existants sur données africaines [12, 56], qui ignorent généralement cette dimension.

Au niveau de l'interprétabilité, l'application des valeurs SHAP [47] à la sécurité alimentaire béninoise répond à un appel explicite de la littérature pour des modèles ML à la fois performants et lisibles pour les décideurs non statisticiens [46]. Cette démarche ouvre la voie à une réconciliation opérationnelle entre les deux paradigmes de modélisation explicatif et prédictif que [69] avait théorisée sans l'appliquer à ce contexte spécifique.

Au niveau empirique, les résultats produits enrichiront la base de connaissances sur les déterminants de l'insécurité alimentaire au Bénin, en comblant les lacunes identifiées dans la littérature béninoise (Section 2.2) et en fournissant des estimations prédictives à l'échelle communale inexistantes à ce jour.

2.6.2 Intérêt opérationnel

Sur le plan opérationnel, la présente étude répond à un besoin concret et urgent des acteurs humanitaires et de développement intervenant au Bénin.

Pour le Programme Alimentaire Mondial (PAM) et ses partenaires institutionnels, la cartographie communale du risque prédit d'insécurité alimentaire constitue un outil de ciblage géographique directement mobilisable pour l'allocation des ressources alimentaires, la planification des missions d'évaluation terrain et la justification des demandes de financement auprès des bailleurs de fonds internationaux.

Pour les organisations non gouvernementales intervenant dans les secteurs de la nutrition, de l'agriculture et de la protection sociale, l'outil d'aide à la prise de décision développé dans l'OS4 permettra de produire des prédictions du statut alimentaire de

ménages hors échantillon à partir de leurs propres données de terrain, sans nécessiter de compétences statistiques avancées.

Pour l’Institut National de la Statistique et de la Démographie (INSTAD) et les services de planification du Ministère du Plan, les résultats fourniront une base empirique pour l’identification des zones prioritaires d’intervention dans le cadre du Plan National de Développement 2018–2025 et du Programme d’Action du Gouvernement (PAG 2021–2026), notamment pour les objectifs de réduction de la malnutrition chronique et d’amélioration de la sécurité alimentaire.

2.6.3 Intérêt pour les politiques publiques

Sur le plan des politiques publiques, la présente étude s’inscrit dans le cadre des engagements internationaux du Bénin en matière de sécurité alimentaire et nutritionnelle.

Au regard de l’ODD 2 (Faim Zéro), les résultats permettront de mesurer l’écart entre la situation actuelle et les cibles fixées pour 2030, et d’identifier les leviers d’action prioritaires pour réduire la prévalence de l’insécurité alimentaire dans les communes les plus vulnérables.

Au regard du Cadre Stratégique pour la Sécurité Alimentaire et Nutritionnelle (CSSAN), la cartographie communale du risque fournira une base empirique pour la révision des critères d’éligibilité des zones d’intervention prioritaires, en substituant une approche fondée sur des probabilités prédites individuellement validées aux critères administratifs souvent arbitraires actuellement utilisés.

Au regard de l’efficacité budgétaire, dans un contexte de ressources publiques et d’aide internationale structurellement insuffisantes au regard des besoins, le ciblage précis des ménages et communes les plus vulnérables est une condition nécessaire bien que non suffisante de l’efficacité des politiques d’assistance alimentaire [5].

2.6.4 But de la recherche

Au terme de cette analyse des intérêts scientifique, opérationnel et politique, le **but ultime** de la présente recherche peut être formulé ainsi :

Produire, à partir des données de l’AGVSAN, un système intégré d’analyse, de prédiction et de cartographie du risque d’insécurité alimentaire des ménages béninois, fondé sur une démarche scientifique rigoureuse et comparative, et déployé sous la forme d’un outil opérationnel accessible aux acteurs humanitaires et aux décideurs politiques au Bénin, afin de contribuer à l’amélioration du ciblage des interventions et, in fine, à la réduction de la vulnérabilité alimentaire sur le territoire national.

Ce but se décline en quatre objectifs spécifiques articulés et mesurables (OS1 à OS4),

dont la cohérence interne avec les questions de recherche et les hypothèses testables est résumée dans le tableau synoptique ci-après (Table 1).

2.7 Tableau de cohérence interne du cadre de recherche

Le tableau 1 résume la cohérence interne entre les questions de recherche, les objectifs spécifiques et les hypothèses testables.

TABLE 1 – Tableau de cohérence : questions, objectifs et hypothèses

Axe	Question de recherche	Objectif spécifique	Hypothèse testable
1	Quels déterminants influencent le risque d'insécurité alimentaire ?	OS1 – Identifier les déterminants via la Régression Logistique	H_1 : Éducation, revenus, eau potable et milieu rural sont des déterminants significatifs
2	Quel modèle offre la meilleure performance prédictive hors-échantillon ?	OS2 – Comparer <i>Logit</i> , <i>Random Forest</i> et <i>XGBoost</i> via AUROC, Recall, F1-score, Brier Score et valeurs SHAP	H_2 : <i>Random Forest</i> et <i>XGBoost</i> surpassent le <i>Logit</i> (AUROC supérieure, test de DeLong, $\alpha = 5\%$)
3	Comment spatialiser les prédictions pour cibler géographiquement les ménages vulnérables ?	OS3 – Cartographier le risque prédit à l'échelle communale et départementale	H_3 : Autocorrélation spatiale positive et significative ; vulnérabilité concentrée dans les départements septentrionaux
4	Le modèle peut-il être déployé dans un outil opérationnel ?	OS4 – Développer une application web de prédiction et de cartographie dynamique	H_4 : Stabilité et calibration suffisantes pour des prédictions fiables hors échantillon

3 Revue de littérature

Dans cette section nous allons présenter et étayer empiriquement l'évolution conceptuelle de la sécurité alimentaire, l'analyse de ses déterminants à travers les cadres analytiques établis dans la littérature, discuter des approches de mesure et de leurs limites, puis examiner les approches de modélisation statistique classiques et par machine learning en insistant sur les méthodes d'interprétabilité modernes, en faisant dialoguer les auteurs plutôt qu'en les listant.

3.1 Évolution conceptuelle de la sécurité alimentaire

3.1.1 De la disponibilité agrégée à l'accès individuel : une révolution paradigmatique

La notion de sécurité alimentaire a traversé depuis les années 1970, une transformation conceptuelle profonde qui s'est construite en réaction à des évidences empiriques troublantes. Dans sa formulation originelle, issue de la première Conférence Mondiale de l'Alimentation de Rome en 1974, la sécurité alimentaire était définie presque exclusivement par le prisme de la *disponibilité* : il s'agissait de garantir, à tout moment, des approvisionnements alimentaires mondiaux et nationaux suffisants pour soutenir l'expansion de la consommation alimentaire et compenser les fluctuations de la production et des prix [59]. Cette conception, d'inspiration néo-malthusienne, postulait une correspondance quasi automatique entre le niveau de production agrégée et l'état nutritionnel des populations.

La première fissure sérieuse dans ce paradigme disponibilitaire est apparue avec l'analyse des grandes famines du XX^e siècle. Les travaux fondateurs d'Amartya Sen, cristallisés dans son ouvrage *Poverty and Famines* [67], constituent la rupture épistémologique la plus décisive de l'histoire de la pensée sur la sécurité alimentaire. En disséquant les données de la famine bengalie de 1943, du Bangladesh de 1974, de l'Éthiopie de 1972–1974 et du Sahel de 1972–1973, Sen démontre avec une rigueur empirique que ces catastrophes humanitaires se sont produites sans qu'il y ait eu de chute significative de la disponibilité alimentaire globale dans les zones affectées. La conclusion théorique de Sen est radicale : ce qui provoque la faim dans une famine, ce n'est pas l'absence de nourriture dans l'espace géographique, c'est l'absence de *droits d'accès* (*entitlements*) à cette nourriture [67].

La théorie des droits distingue quatre mécanismes par lesquels un individu peut légitimement acquérir de la nourriture : la dotation directe (production propre), les échanges commerciaux (achat sur les marchés), le travail (salaire échangeable contre des aliments), et les transferts (dons, aide sociale). L'insécurité alimentaire survient lorsque

la carte des droits d'un ménage se réduit au point de ne plus permettre d'accéder à une alimentation minimale [67]. Cette réorientation de l'*offre* vers la *distribution* et de l'*agrégat* vers l'*individu* a profondément restructuré la recherche en sécurité alimentaire pour les quatre décennies suivantes.

3.1.2 La consolidation dans les années 1990–2000 : les quatre piliers

Les travaux de Maxwell et Frankenberger [50] ont proposé un cadre analytique distinguant la sécurité alimentaire au niveau *macro* (national et mondial) et au niveau *micro* (ménage et individu). C'est dans cette perspective de synthèse que s'inscrit la définition canonique formulée lors du Sommet Mondial de l'Alimentation de Rome en 1996, qui consacre quatre piliers désormais universellement reconnus : **disponibilité**, **accès**, **utilisation** et **stabilité** [25].

La notion d'**utilisation** opère un déplacement analytique majeur de l'alimentation vers la *nutrition* : un ménage peut avoir accès à des aliments suffisants et néanmoins présenter des signes de malnutrition si ces aliments ne peuvent être correctement absorbés par l'organisme, en raison d'une infection parasitaire chronique, d'un mauvais état des infrastructures d'eau et d'assainissement, ou de pratiques d'alimentation inadéquates [75]. La notion de **stabilité**, quant à elle, recouvre la dimension temporelle : une sécurité alimentaire véritablement durable exige que l'accès à une alimentation adéquate soit maintenu dans le temps, sans être compromis par des chocs saisonniers, climatiques ou économiques récurrents [25]. Cette dimension est cruciale dans le contexte béninois où les ménages agricoles sont exposés à des variations saisonnières importantes de leurs revenus et de leur production.

3.1.3 La complexité contemporaine : vers un cadre hexadimensionnel

Depuis la fin des années 2000, plusieurs courants de recherche ont plaidé pour un enrichissement du cadre quadripolaire. La FAO elle-même a progressivement intégré deux dimensions supplémentaires dans ses publications récentes [27] : la **durabilité** des systèmes alimentaires face aux pressions environnementales, et l'**agence** (*agency*), définie comme la capacité des individus à exercer leurs choix alimentaires de manière autonome et éclairée, sans être contraints par des rapports de pouvoir intra-ménage ou des normes culturelles restrictives. Cette dernière dimension ouvre un champ de recherche spécifique sur les inégalités de genre dans l'accès à la nourriture au sein des ménages [31].

Ces enrichissements conceptuels suscitent cependant un débat méthodologique légitime. Coates [16] souligne que l'inflation conceptuelle de la sécurité alimentaire risque de nuire à la mesure et à la comparabilité internationale. Plus fondamentalement, Carletto, Zezza et Banerjee [13] ont montré empiriquement que les différents indicateurs

opérationnels de la sécurité alimentaire présentent une corrélation imparfaite et peuvent classer les mêmes ménages différemment, ce qui renforce l'importance du choix et de la justification rigoureuse de l'indicateur retenu comme variable dépendante — choix que nous développons dans la section méthodologique.

3.2 Mesure de la sécurité alimentaire : indicateurs, forces et limites

3.2.1 Le Score de Consommation Alimentaire : atouts et limites documentées

Le Score de Consommation Alimentaire (SCA) est l'indicateur composite standardisé développé par le PAM [78] pour mesurer l'accès alimentaire des ménages à partir de la fréquence et de la diversité de leur consommation alimentaire sur les sept jours précédant l'enquête. Il est calculé comme la somme pondérée des fréquences de consommation de huit groupes alimentaires, les pondérations reflétant la valeur nutritionnelle relative de chaque groupe. Sa simplicité de calcul, sa robustesse empirique démontrée dans de nombreux contextes africains et sa standardisation internationale en font l'indicateur de référence pour les enquêtes de sécurité alimentaire du PAM dans plus de 60 pays [78].

Plusieurs études ont validé la pertinence du SCA comme proxy de la sécurité alimentaire des ménages. Hoddinott et Yohannes [36], dans une analyse comparative portant sur 10 pays en développement, ont montré que le SCA présente une forte corrélation avec les dépenses alimentaires par tête (coefficient de corrélation moyen de 0,72) et avec les indicateurs anthropométriques d'état nutritionnel des enfants, validant sa pertinence comme mesure synthétique de l'accès alimentaire. Swindale et Bilinsky [74] ont confirmé ces résultats dans le contexte africain, montrant que le SCA capture efficacement les variations saisonnières de l'accès alimentaire et discrimine bien les ménages pauvres des ménages non pauvres.

Cependant, la littérature récente a documenté plusieurs **limites et biais du SCA** que tout travail de modélisation rigoureux doit reconnaître explicitement :

Limite 1 – Qualité nutritionnelle non capturée : Le SCA mesure la *fréquence* et la *diversité* de la consommation alimentaire mais ne renseigne pas sur la *quantité* réelle consommée ni sur la *qualité nutritionnelle* intrinsèque des aliments au sein de chaque groupe. Un ménage consommant quotidiennement des céréales raffinées et du sucre peut obtenir un SCA élevé tout en présentant des déficiences micronutritionnelles importantes [16].

Limite 2 – Sensibilité à la saisonnalité : Les fréquences de consommation alimentaire varient considérablement selon la saison agricole. Un SCA collecté en période post-récolte (abondance) sera systématiquement supérieur au même ménage inter-

rogé en période de soudure (pénurie) [49]. Cette sensibilité saisonnière implique que les données AGVSAN 2017 reflètent la situation alimentaire à un moment précis du calendrier agricole béninois, ce qui doit être pris en compte dans l'interprétation des résultats.

Limite 3 – Risque de surclassement : Le SCA peut surestimer la sécurité alimentaire de ménages qui consomment régulièrement un faible nombre de groupes alimentaires à haute fréquence (par exemple, des céréales quotidiennement et des légumineuses fréquemment) en obtenant un score qui dépasse le seuil de 42, alors même que leur diversité alimentaire réelle et leur état nutritionnel sont insuffisants [13].

Limite 4 – Non-prise en compte des portions : Contrairement aux méthodes de rappel alimentaire sur 24 heures, le SCA ne collecte pas les quantités consommées. Deux ménages consommant la même diversité alimentaire mais en quantités très différentes obtiendront des scores identiques, alors que leurs situations nutritionnelles réelles divergent [36].

Ces limites justifient l'utilisation d'indicateurs complémentaires l'Indice des Stratégies de Survie (ISS/*rCSI*) et l'Échelle HFIAS comme variables de validation croisée dans notre démarche et la conduite d'une analyse de sensibilité des seuils de classification décrite dans la section méthodologique.

3.2.2 Autres indicateurs : HFIAS, *rCSI* et CARI

L'Échelle d'Insécurité Alimentaire des Ménages (HFIAS, *Household Food Insecurity Access Scale*) [17] mesure la perception subjective de l'insécurité alimentaire à travers neuf questions portant sur les quatre semaines précédant l'enquête, couvrant les dimensions d'anxiété, de restriction qualitative et de restriction quantitative. Sa force réside dans sa capacité à capturer l'expérience vécue de l'insécurité alimentaire au-delà des comportements observables, mais sa sensibilité aux normes culturelles locales concernant l'expression de la vulnérabilité constitue une limite dans les contextes où la divulgation de la pauvreté est socialement stigmatisée [16].

L'Indice Réduit des Stratégies de Survie (*reduced Coping Strategies Index – rCSI*) [48] quantifie la fréquence de recours à des comportements d'adaptation alimentaire négatifs (réduction des repas, consommation d'aliments moins préférés, emprunt de nourriture) au cours des sept jours précédents. Il présente l'avantage de mesurer les *réponses comportementales* à l'insécurité alimentaire plutôt que ses manifestations directes, ce qui le rend particulièrement sensible aux chocs alimentaires transitoires. Carletto et al. [13] ont montré que le SCA et le *rCSI* présentent une corrélation modérée (0,45 à 0,60 selon les contextes), confirmant qu'ils capturent des dimensions partiellement distinctes de l'insécurité alimentaire, ce qui justifie leur utilisation conjointe dans une

démarche de validation croisée.

Le Cadre Intégré de Classification de la Sécurité Alimentaire (CARI – *Consolidated Approach for Reporting Indicators of Food Security*) [79] constitue l’approche la plus récente et la plus complète, combinant le SCA, le *rCSI* et les dépenses alimentaires pour classer les ménages en quatre catégories de sécurité alimentaire. Son adoption croissante par le PAM dans ses enquêtes récentes suggère qu’il pourrait constituer la variable dépendante de référence pour les futures études, mais sa disponibilité limitée dans les données AGVSAN 2017 justifie notre recours au SCA comme indicateur principal.

3.3 Les déterminants de la sécurité alimentaire des ménages : revue empirique

3.3.1 Cadres analytiques structurants

Deux cadres analytiques complémentaires structurent la revue des déterminants. Le cadre conceptuel de l’UNICEF sur les causes de la malnutrition [75] organise les déterminants en trois niveaux causaux imbriqués : les causes *immédiates* (apport alimentaire insuffisant et maladies infectieuses) ; les causes *sous-jacentes* (insécurité alimentaire du ménage, pratiques de soins et d’alimentation inadéquates, environnement sanitaire déficient) ; et les causes *fondamentales* ou structurelles (pauvreté, inégalités, gouvernance défailante). Ce cadre est particulièrement utile pour éviter les confusions de niveaux analytiques fréquentes dans la littérature.

En parallèle, le cadre des Moyens d’Existence Durables (*Sustainable Livelihoods Framework* – SLF) développé par le DFID [21] offre une architecture opérationnelle pour classer les déterminants selon cinq *capitaux* : humain, social, naturel, physique et financier. C’est l’articulation de ces cadres qui structure la sélection des variables indépendantes dans notre démarche.

3.3.2 Capital humain : éducation, genre et composition du ménage

L’éducation du chef de ménage est l’un des déterminants les plus robustement documentés de la sécurité alimentaire dans la littérature africaine. Plusieurs mécanismes de transmission ont été identifiés. Premièrement, un niveau d’instruction plus élevé est associé à une capacité accrue à adopter des pratiques agricoles améliorées, à accéder à l’information sur les marchés et à diversifier les sources de revenus [55]. Deuxièmement, l’éducation maternelle joue un rôle spécifique sur l’utilisation des aliments : les femmes plus instruites présentent des enfants avec des taux de malnutrition chronique inférieurs [70]. Troisièmement, dans des études menées au Kenya, en Tanzanie et au Nigeria, Ogunniyi et al. [55] montrent que chaque niveau d’éducation supplémentaire du chef de ménage est associé à une réduction significative de la probabilité d’insécurité alimentaire.

La question du genre du chef de ménage a fait l'objet d'une littérature abondante aux conclusions nuancées. Une méta-analyse conduite par Doss [22] sur 51 études africaines montre que lorsque l'on contrôle pour la composition du ménage et l'accès aux ressources productives, l'effet propre du sexe du chef de ménage sur la sécurité alimentaire disparaît ou s'inverse dans plusieurs contextes. Pour le Bénin spécifiquement, Azonhiho et al. [3] documentent une vulnérabilité accrue des ménages dirigés par des femmes, attribuée principalement à leur moindre accès aux ressources foncières plutôt qu'au genre résultat qui souligne l'importance des interactions entre variables dans la modélisation.

La taille et la composition du ménage constituent des déterminants importants agissant via le ratio de dépendance. Deaton et Paxson [19] ont démontré que les ménages plus nombreux présentent des dépenses alimentaires par tête significativement inférieures, même à revenu total constant, illustrant un effet de dilution des ressources. Au Bénin, où la taille moyenne des ménages ruraux dépasse cinq membres, cette dynamique est particulièrement pertinente.

3.3.3 Capital économique et financier : pauvreté, revenus et diversification

L'approche des pièges à pauvreté (*poverty traps*) développée par Barrett et Carter [5] apporte un éclairage théorique crucial : certains ménages ruraux en Afrique subsaharienne sont piégés dans des équilibres de bas niveau où la malnutrition chronique réduit leur capital humain, ce qui comprime leurs revenus agricoles, perpétuant la pauvreté et l'insécurité alimentaire dans un cercle vicieux auto-entretenu. Cette dynamique non-linéaire implique que la relation entre revenu et sécurité alimentaire n'est pas nécessairement continue et peut présenter des discontinuités (seuils), ce qui justifie le recours à des méthodes capables de capturer ces non-linéarités — comme les algorithmes de machine learning.

La diversification des sources de revenus est identifiée comme l'un des mécanismes de résilience les plus efficaces contre l'insécurité alimentaire. Dans une étude portant sur 15 pays d'Afrique subsaharienne, Babatunde et Qaim [4] montrent que les ménages disposant d'au moins trois sources de revenus distinctes présentent une probabilité d'insécurité alimentaire significativement inférieure à ceux dépendant d'une source unique, même après contrôle du niveau de revenu total.

3.3.4 Capital naturel : accès à la terre, bétail et ressources environnementales

L'accès à la terre agricole est un déterminant structurel de première importance pour les ménages ruraux. La sécurité foncière au-delà de la simple superficie cultivée conditionne les décisions d'investissement dans l'amélioration de la fertilité des sols et les

infrastructures d'irrigation [26]. Dans les contextes d'insécurité foncière caractéristiques du nord du Bénin, les ménages hésitent à réaliser des investissements à long terme, perpétuant une agriculture de subsistance peu productive [3].

La possession de bétail remplit une double fonction dans la stratégie alimentaire des ménages ruraux : elle contribue directement à la diversité alimentaire et indirectement à la production agricole ; elle constitue également une épargne mobilisable en cas de choc, permettant de lisser la consommation alimentaire [23].

3.3.5 Capital physique et localisation : infrastructures et milieu de résidence

L'accès à l'eau potable agit principalement via le pilier "utilisation" : une eau contaminée entraîne des pathologies diarrhéiques qui compromettent l'absorption intestinale des nutriments, entretenant un cycle malnutrition-infection bien documenté [75]. Dans une revue systématique portant sur 18 études africaines, Headey et Ecker [35] montrent que l'accès à une source d'eau améliorée réduit la prévalence de la malnutrition chronique chez les enfants de manière indépendante du niveau de revenu.

L'enclavement géographique augmente les coûts de transaction d'accès aux marchés, renchérissant les denrées importées et aggravant la sécurité alimentaire des ménages déficitaires [6]. Au Bénin, la corrélation spatiale entre enclavement et insécurité alimentaire est particulièrement marquée dans les communes du nord-est (Alibori) où les distances aux marchés de référence excèdent plusieurs dizaines de kilomètres [62].

3.3.6 Capital social et politiques publiques

Les réseaux d'entraide informels constituent un mécanisme de gestion collective des risques alimentaires, mais leur efficacité est compromise lorsque le choc est covariant (sécheresse affectant simultanément tous les membres du réseau) [23]. Les politiques publiques de protection sociale transferts monétaires conditionnels, programmes d'alimentation scolaire ont montré des effets positifs documentés sur la sécurité alimentaire de leurs bénéficiaires [77]. Au Bénin, les programmes de filets sociaux restent d'une couverture limitée par rapport à l'ampleur des besoins, ce qui renforce l'importance d'un ciblage géographique et socio-économique précis des interventions objectif auquel ce mémoire entend contribuer méthodologiquement.

3.4 Modélisation économétrique du risque alimentaire : approches classiques

3.4.1 La régression logistique binaire : modèle canonique et limites

La régression logistique binaire est devenue le modèle de référence pour l'analyse des déterminants de l'insécurité alimentaire des ménages. Feleke, Kilmer et Gladwin [24], dans une étude pionnière sur les déterminants de la sécurité alimentaire dans le sud de l'Éthiopie, mobilisent un Logit binaire et concluent que la superficie cultivée, l'accès au crédit, la diversification des revenus et le niveau d'éducation du chef de ménage sont des déterminants significatifs. Ogunniyi et al. [55] au Nigeria arrivent à des conclusions similaires tout en documentant l'effet négatif de la taille du ménage.

Dans le contexte béninois, Azonhiho et al. [3] documentent des résultats similaires, avec une persistance de la vulnérabilité alimentaire dans les zones septentrionales indépendamment du niveau de revenu, suggérant l'importance de facteurs structurels géographiques non capturés par les seules variables économiques. Cette étude constitue la référence économétrique la plus directement comparable au présent travail pour le Bénin, bien qu'elle ne procède pas à une évaluation rigoureuse des performances prédictives hors-échantillon — ce qui constitue précisément l'une des lacunes que notre démarche entend combler.

Cependant, la régression logistique présente des limitations sérieuses dans une perspective prédictive. Harrell [32] identifie trois problèmes récurrents : (i) l'hypothèse de linéarité dans le logit, fréquemment violée dans les données d'enquêtes aux distributions très asymétriques ; (ii) la sensibilité à la multicolinéarité, qui gonfle les variances des estimateurs ; (iii) l'absence de prise en compte automatique des interactions entre prédicteurs. Sur le plan prédictif, Shmueli [69] souligne que les modèles économétriques conçus pour l'inférence causale maximisent la vraisemblance sur l'échantillon d'estimation, sans garantie de performance sur des données nouvelles.

3.5 Modélisation par machine learning du risque alimentaire

3.5.1 Pertinence et avantages comparatifs du machine learning

Shmueli [69] pose clairement la distinction conceptuelle entre modélisation *explicative* (tester des relations causales hypothétiques paradigme économétrique) et modélisation *prédictive* (maximiser la précision de la prédiction sur des données non vues paradigme ML). Cette distinction ne hiérarchise pas les approches mais souligne leur complémentarité : le Logit demeure irremplaçable pour l'inférence causale sur les déterminants, tandis que les algorithmes ML sont supérieurs pour le ciblage prédictif des ménages vulnérables. C'est cette complémentarité que le présent mémoire exploite en mobilisant

les deux paradigmes de manière articulée.

Le recours aux algorithmes ML répond à trois limites identifiées des approches économétriques classiques. Premièrement, les algorithmes basés sur les arbres de décision modélisent naturellement les non-linéarités et les interactions entre variables sans spécification préalable [34]. Deuxièmement, les méthodes ensemblistes comme le *Random Forest* et l'*XGBoost* optimisent explicitement la performance prédictive hors-échantillon [15]. Troisièmement, ces algorithmes produisent des mesures d'importance des variables qui, combinées aux méthodes d'interprétabilité modernes comme les valeurs SHAP, permettent d'identifier les déterminants les plus prédictifs tout en maintenant une lisibilité pour les décideurs [47].

3.5.2 Random Forest : principe, performances et applications en sécurité alimentaire

Le *Random Forest* a été introduit par Breiman [10] comme une généralisation du bagging enrichie d'une randomisation des variables à chaque nœud. L'intuition fondamentale est que la combinaison de nombreux classifieurs "faibles" (arbres individuels) mais *diversifiés* produit un classifieur "fort" dont la variance est considérablement réduite, sans augmentation substantielle du biais. L'erreur hors-bag (OOB) fournit une estimation interne non biaisée de l'erreur de généralisation, propriété particulièrement précieuse pour la sélection des hyperparamètres.

Les applications du *Random Forest* à la sécurité alimentaire se sont multipliées. Browne et al. [12] ont appliqué une version multivariée du *Random Forest* à des données d'enquêtes nationales de 12 pays pour prédire simultanément la pauvreté et la malnutrition, obtenant des performances prédictives (AUROC $\approx 0,82$) significativement supérieures à celles d'une régression logistique de référence (AUROC $\approx 0,74$). Andrée et al. [2] ont utilisé le *Random Forest* combiné à des données de flux d'actualités pour prédire les crises alimentaires à 12 mois d'horizon. Dans le contexte nigérian, Ojo et Baiyegunhi [56] rapportent que le *Random Forest* classe correctement 84 % des ménages contre 76 % pour le Logit sur un problème de prédiction de la sécurité alimentaire. Un atout particulièrement utile du *Random Forest* est sa robustesse à la multicollinéarité, contrairement au Logit dont les coefficients deviennent instables en présence de prédicteurs très corrélés [34].

3.5.3 XGBoost : optimisation avancée et état de l'art prédictif

L'*XGBoost* [15] est une implémentation algorithmiquement optimisée du Gradient Boosting Machine originellement proposé par Friedman [30]. Son principe fondamental diffère radicalement du *Random Forest* : plutôt que de construire des arbres indépendants et de les agréger, le Gradient Boosting construit une séquence d'arbres où chaque

nouvel arbre est entraîné sur les *pseudo-résidus* du modèle précédent. Ce mécanisme de correction itérative permet au Gradient Boosting de réduire à la fois le biais et la variance [30].

Les innovations d'*XGBoost* incluent : une régularisation explicite $\gamma T + \frac{1}{2}\lambda\|\mathbf{w}\|^2$ qui pénalise la complexité et prévient le surapprentissage ; un algorithme d'approximation par histogrammes qui accélère le calcul sur les grandes bases de données ; et un mécanisme d'arrêt précoce (*early stopping*) qui optimise automatiquement le nombre d'itérations [15]. Empiriquement, *XGBoost* s'est imposé comme l'algorithme dominant pour les données tabulaires dans les compétitions de *machine learning* depuis 2016. Les travaux récents sur données africaines confirment la supériorité prédictive des algorithmes ensemblistes sur la régression logistique, avec des AUROC généralement supérieures de 0,10 à 0,15 points selon les contextes [12, 56].

3.5.4 Interprétabilité des modèles ML : des importances classiques aux valeurs SHAP

Un reproche récurrent adressé aux algorithmes ML est leur caractère de “boîte noire” (*black box*), qui compromet leur adoption par les décideurs politiques et humanitaires qui ont besoin de comprendre *pourquoi* un ménage est classé comme vulnérable pour justifier les interventions ciblées. Ce reproche, légitime dans le contexte de la recherche en développement, a conduit à l'émergence d'un champ de recherche dédié : l'intelligence artificielle explicable.

Limites des mesures d'importance classiques Les mesures d'importance classiques la *Mean Decrease in Accuracy* (MDA) et la *Mean Decrease in Gini* (MDG) pour le *Random Forest*, et le *Gain*, la *Cover* et la *Frequency* pour l'*XGBoost* présentent des limitations documentées. Strobl et al. [72] ont montré que la MDG est biaisée en faveur des variables continues ou à haute cardinalité, surestimant systématiquement leur importance relative par rapport aux variables binaires. La MDA est moins biaisée mais très variable d'un échantillon à l'autre. Ces limites impliquent que les importances classiques ne constituent pas une mesure fiable de la contribution causale de chaque variable à la prédiction.

Les valeurs SHAP : un standard d'interprétabilité Lundberg et Lee [47] ont proposé les valeurs SHAP (*SHapley Additive exPlanations*) comme cadre unifié et mathématiquement rigoureux pour l'interprétabilité des modèles ML. Fondées sur la théorie des jeux coopératifs de Shapley [68], les valeurs SHAP attribuent à chaque variable X_j une contribution $\phi_j(\mathbf{x}_i)$ à la prédiction du modèle pour l'observation i , définie comme sa contribution marginale moyenne sur toutes les coalitions possibles de variables :

$$\phi_j(\mathbf{x}_i) = \sum_{S \subseteq \mathcal{F} \setminus \{j\}} \frac{|S|! (|\mathcal{F}| - |S| - 1)!}{|\mathcal{F}|!} [f_{S \cup \{j\}}(\mathbf{x}_i) - f_S(\mathbf{x}_i)] \quad (1)$$

où $\mathcal{F}$ est l'ensemble des variables, S une coalition de variables excluant j , et f_S la prédiction du modèle restreint à S . Les valeurs SHAP satisfont trois propriétés axiomatiques fondamentales : *efficience* (la somme des valeurs SHAP égale la différence entre la prédiction et la valeur de référence du modèle) ; *symétrie* (deux variables avec des contributions identiques reçoivent des valeurs SHAP identiques) ; *monotonicité* (une variable contribuant davantage dans un modèle reçoit une valeur SHAP plus élevée) [47].

Plusieurs avantages distinguent les valeurs SHAP des importances classiques pour notre contexte d'application :

Interprétabilité locale : Les valeurs SHAP permettent d'expliquer la prédiction pour *chaque ménage individuellement* ("pourquoi ce ménage spécifique est-il classé comme vulnérable?"), ce qui est directement utile pour le ciblage programmatique.

Interprétabilité globale : La moyenne des valeurs absolues des SHAP sur l'ensemble des ménages fournit une mesure d'importance globale non biaisée, comparable entre variables de natures différentes (binaires, continues, polytomiques).

Visualisation des interactions : Les graphiques SHAP (*summary plot*, *dependence plot*, *waterfall plot*) permettent de visualiser la direction et l'amplitude de l'effet de chaque variable sur le risque prédit, avec une lisibilité directement accessible pour les décideurs non statisticiens.

Comparabilité entre modèles : Les valeurs SHAP peuvent être calculées pour le Logit, le *Random Forest* et l'*XGBoost*, permettant une comparaison directe des structures d'interprétabilité entre les trois modèles [46].

Les applications récentes des valeurs SHAP à la sécurité alimentaire en Afrique confirment leur pertinence opérationnelle dans ce domaine. Plusieurs travaux ont montré que les SHAP révèlent des déterminants accès aux marchés, diversification des cultures, interactions entre genre et accès au crédit qui n'émergent pas clairement des analyses économétriques classiques, soulignant la complémentarité entre les deux approches [46, 47].

Implémentation pratique Dans notre étude, les valeurs SHAP seront calculées pour les trois modèles via la bibliothèque Python **shap** [47], implémentation de référence développée par les auteurs mêmes de la méthode, qui fournit les algorithmes TREE SHAP de Lundberg et al. [46] pour les modèles basés sur les arbres (*Random Forest* et *XGBoost*, via **shap.TreeExplainer**) et l'algorithme LINEAR SHAP pour la Régression Logistique (via **shap.LinearExplainer**). Les visualisations produites incluront un *summary plot* (importance globale et direction des effets), des *dependence plots* pour les variables les

plus importantes, et des *waterfall plots* pour l'explication de prédictions individuelles représentatives.

3.6 Calibration des modèles de classification

Un aspect souvent négligé dans la littérature sur la prédiction de l'insécurité alimentaire est la **calibration** des probabilités prédites. Un modèle est dit bien calibré si, parmi tous les ménages à qui il attribue une probabilité prédite de 70 %, environ 70 % sont effectivement en insécurité alimentaire. La calibration est distincte de la discrimination (AUROC) : un modèle peut avoir une excellente capacité discriminante (distinguer les ménages vulnérables des non vulnérables) tout en produisant des probabilités mal calibrées (surestimant ou sous-estimant systématiquement les niveaux de risque absolus) [71].

Cette distinction est cruciale dans notre contexte car les probabilités prédites sont directement utilisées pour la cartographie (agrégation à l'échelle communale) et pour l'outil web (affichage d'un niveau de risque à l'utilisateur). Des probabilités mal calibrées conduiraient à une cartographie du risque biaisée et à des prédictions peu fiables pour les acteurs humanitaires.

Niculescu-Mizil et Caruana [54] ont montré que les algorithmes ensemblistes *Random Forest* en particulier tendent à produire des probabilités *compressées* (proches de 0,5), tandis que *XGBoost* présente généralement une meilleure calibration naturelle. Le Brier Score [11], défini comme :

$$BS = \frac{1}{n} \sum_{i=1}^n (\hat{P}(Y_i = 1) - Y_i)^2 \quad (2)$$

constitue la métrique de référence pour évaluer conjointement la discrimination et la calibration. Un Brier Score de 0 indique des prédictions parfaites ; un score de 0,25 est équivalent à une prédiction aléatoire pour un problème équilibré. Des techniques de recalibration post-hoc la régression isotonique [80] ou la calibration de Platt [60] peuvent améliorer la calibration sans modifier les performances discriminantes du modèle.

3.7 Cartographie de la vulnérabilité alimentaire

La cartographie de la vulnérabilité alimentaire constitue un champ de recherche appliquée qui s'est développé à l'intersection des systèmes d'information géographique (SIG), de la télédétection et de la statistique spatiale. Les premières applications à grande échelle ont été développées par le PAM et l'IFPRI sous la forme d'atlas de la pauvreté et de la faim [6], utilisant des méthodes de *small area estimation* pour produire des estimations géographiques fines.

L’apport spécifique de la modélisation prédictive par ML à la cartographie réside dans la possibilité de prédire la probabilité individuelle d’insécurité alimentaire pour chaque ménage observé dans l’enquête, puis d’agrèger ces probabilités à des échelles géographiques fines [2]. Jean et al. [40] ont combiné les prédictions d’un modèle de Gradient Boosting entraîné sur des données d’enquêtes ménages avec des données de télédétection pour produire une estimation continue de la pauvreté à haute résolution spatiale. Pokhriyal et Jacques [61] ont étendu cette approche aux indicateurs composites de bien-être, montrant qu’il était possible de produire des estimations précises de la vulnérabilité à l’échelle sous-nationale.

La présence d’une **autocorrélation spatiale** dans les probabilités prédites — c’est-à-dire la tendance de communes géographiquement proches à présenter des niveaux de risque similaires — constitue une propriété importante à tester et à documenter. L’indice de Moran [53] est la mesure standard de l’autocorrélation spatiale globale :

$$I = \frac{n}{\sum_u \sum_v w_{uv}} \cdot \frac{\sum_u \sum_v w_{uv} (\bar{P}_u - \bar{P})(\bar{P}_v - \bar{P})}{\sum_u (\bar{P}_u - \bar{P})^2} \quad (3)$$

où $\bar{P}_u$ est la probabilité moyenne prédite dans la commune u , $\bar{P}$ la moyenne nationale, et w_{uv} les poids de la matrice de contiguïté spatiale (égaux à 1 si les communes u et v sont contiguës, 0 sinon). Un indice de Moran positif et significatif confirme l’hypothèse H_3 d’une hétérogénéité spatiale structurée du risque alimentaire au Bénin.

3.8 Synthèse de la revue de littérature et positionnement du présent travail

La revue de littérature conduite dans cette section nous permet de positionner clairement la présente étude dans le paysage scientifique existant. Le tableau 2 résume les principales études de référence et leur positionnement par rapport à notre travail.

TABLE 2 – Positionnement du présent travail par rapport à la littérature existante

Étude	Contexte	Logit	RF / XGB	SHAP	Carto.	Outil web
Feleke et al. (2005)	Éthiopie	✓	×	×	×	×
Babatunde & Qaim (2010)	Nigeria	✓	×	×	×	×
Azonhiho et al. (2020)	Bénin	✓	×	×	×	×
Browne et al. (2021)	12 pays	✓	✓	×	×	×
Présent travail	Bénin	✓	✓	✓	✓	✓

La lecture de ce tableau confirme que la combinaison **Logit + RF + XGBoost + SHAP + Cartographie + Outil** sur des données béninoises constitue une

contribution originale et inédite dans la littérature existante sur la sécurité alimentaire au Bénin et, plus largement, en Afrique de l'Ouest.

4 Matériel et Méthodologie

Dans Cette section, notre point de mire sera de présenter les données, leur justification rigoureuse, le plan de sondage, la construction de la variable dépendante à partir des instruments de mesure réels du questionnaire AGVSAN , les variables indépendantes extraites du questionnaire, les tests statistiques pré-estimation avec leurs hypothèses, règles de décision, les trois modèles de classification retenus avec leurs fondements mathématiques, procédures d'estimation, méthodes d'interprétabilité avancée (SHAP), évaluation de la calibration et critères d'évaluation comparative.

4.1 Source de données : l'enquête AGVSAN Bénin 2017

4.1.1 Présentation et justification du choix des données

La base de données mobilisée est issue de l'Analyse Globale de la Vulnérabilité et de la Sécurité Alimentaire (AGVSAN – également désignée AGVSA dans sa version 2017) réalisée au Bénin en 2017, sous l'égide du Programme Alimentaire Mondial (PAM), en partenariat avec le Ministère chargé du Plan et du Développement et l'Institut National de la Statistique et de l'Analyse Économique (INSAE), devenu depuis l'Institut National de la Statistique et de la Démographie (INSTAD) [62]. Le financement a été assuré par la coopération allemande. Cette enquête transversale à couverture nationale vise à mesurer la prévalence, l'intensité et les déterminants de l'insécurité alimentaire et de la vulnérabilité nutritionnelle des ménages béninois. L'unité d'observation est le ménage, défini comme l'ensemble des personnes vivant sous le même toit, partageant les mêmes repas et reconnaissant l'autorité d'un même chef de ménage.

Justification du choix de cette enquête Le choix de l'AGVSAN 2017 comme source de données repose sur quatre arguments complémentaires :

Argument 1 – Dernière édition disponible : L'AGVSAN 2017 constitue la **dernière édition** de cette enquête spécialisée réalisée au Bénin. Aucune enquête de même nature et de même couverture thématique n'a été conduite depuis lors. Les enquêtes harmonisées sur les conditions de vie des ménages (EHCVM) réalisées en 2018–2019 et 2021–2022 ne collectent pas l'ensemble des modules thématiques de l'AGVSAN notamment les scores de consommation alimentaire détaillés (Section 4), les stratégies de survie (Section 9) et les indicateurs HFIAS ce qui rend la comparaison directe impossible et justifie le recours aux données AGVSAN 2017 comme seule source statistique complète disponible pour la modélisation de l'insécurité alimentaire au Bénin.

Argument 2 – Représentativité nationale : L'enquête couvre l'ensemble des 12

départements et 77 communes du territoire béninois, avec un échantillon de **14 952 ménages** représentatif aux niveaux national et départemental, ce qui confère aux résultats une portée géographique suffisante pour la cartographie communale envisagée dans l'OS3.

Argument 3 – Richesse thématique : Le questionnaire ménage, d'une durée d'administration d'environ 60 minutes, couvre onze sections thématiques permettant de renseigner les cinq capitaux du cadre des Moyens d'Existence Durables (SLF) [21] : démographie et éducation (S1), migration (S2), habitat et équipements (S3), consommation alimentaire et sources des aliments (S4), sources de revenus et moyens d'existence (S5), crédit et dépenses (S6), agriculture (S7), élevage (S8), chocs et stratégies d'adaptation (S9), assistances et priorités (S10), et surveillance par téléphone mobile (S11).

Argument 4 – Instruments de mesure standardisés : L'AGVSAN 2017 utilise les instruments standardisés du PAM le SCA, le *rCSI* et le HFIAS dont la validité de construit a été documentée dans de nombreux contextes africains [78], garantissant la comparabilité internationale des résultats.

Reconnaissance de la limite temporelle Il convient de reconnaître explicitement la limite liée à l'ancienneté relative des données. Collectées en 2017, elles ne reflètent pas les perturbations majeures survenues depuis lors : la pandémie de COVID-19 (2020–2021) qui a perturbé les chaînes d'approvisionnement alimentaires et réduit les revenus des ménages les plus vulnérables ; la dégradation sécuritaire dans les départements septentrionaux du Bénin (Alibori, Atacora) liée à la déstabilisation du Sahel (2021–présent) ; et la crise inflationniste mondiale des prix alimentaires consécutive au conflit russo-ukrainien (2022). Ces événements ont vraisemblablement aggravé la situation alimentaire dans les zones déjà fragiles identifiées par l'AGVSAN 2017, ce qui suggère que nos estimations constituent plutôt un *plancher* de la vulnérabilité actuelle. Cette limite est prise en compte dans l'interprétation des résultats et les recommandations de politique, et justifie le déploiement d'un outil d'aide à la prise de décision (OS4) permettant des mises à jour dès que de nouvelles données seront disponibles.

4.1.2 Plan de sondage et représentativité

L'enquête AGVSAN 2017 repose sur un plan de sondage probabiliste *stratifié à deux degrés*, conçu pour garantir la représentativité des estimations aux niveaux national et départemental [18]. Les informations de stratification disponibles dans le questionnaire (variables 0.1.3 à 0.1.7) permettent de reconstituer la structure de l'échantillon.

Premier degré Les unités primaires de sondage sont des *grappes* (villages en milieu rural, quartiers en milieu urbain), identifiées dans le questionnaire par la variable 0.1.9

- **Numéro de grappe** (3 chiffres). Les grappes sont tirées au sein de chaque strate définie par le croisement département $\times$ milieu de résidence (0.1.7 : Urbain = 1, Rural = 2), avec une probabilité proportionnelle à leur taille démographique issue du Recensement Général de la Population et de l'Habitation.

Second degré Au sein de chaque grappe sélectionnée, un nombre fixe de ménages est tiré de manière systématique, identifiés par la variable 0.1.10 - **Numéro de ménage**. L'ensemble du territoire béninois est couvert à travers les 12 départements (0.1.3), leurs communes (0.1.4), arrondissements (0.1.5–0.1.6) et villages/quartiers (0.1.8).

Taille de l'échantillon et procédure de nettoyage La taille brute de l'enquête est de **14 952 ménages**. La taille finale de l'échantillon analytique après nettoyage sera déterminée en excluant : (i) les ménages pour lesquels le SCA ne peut être calculé en raison de valeurs manquantes sur les items de la Section 4 ; (ii) les observations présentant des valeurs aberrantes manifestes sur les variables clés (revenus négatifs, tailles de ménage incohérentes). La taille exacte de l'échantillon analytique final sera reportée dans la section des résultats descriptifs.

Ce plan de sondage complexe implique une corrélation intra-grappe des observations et des probabilités d'inclusion inégales entre strates. Les analyses statistiques intègrent systématiquement les *pondérations d'échantillonnage* pour produire des estimations représentatives de la population de référence, conformément aux recommandations méthodologiques pour les enquêtes à plan de sondage complexe [18].

4.2 Construction de la variable dépendante

4.2.1 Choix de l'indicateur de sécurité alimentaire : utilisation de la classification officielle déjà disponible

L'exploration de la base AGVSAN 2017 a permis d'identifier que le fichier de données brutes contient une variable pré-calculée, `Round_INDICE_SECAL` (« Classe de Sécurité Alimentaire »), directement élaborée par le PAM et l'INSAE selon leur méthodologie officielle de classification des ménages. Plutôt que de reconstruire cette classification de manière indépendante à partir des items bruts de consommation, nous retenons **directement cette variable officielle comme fondement de la variable dépendante**, pour quatre raisons :

Fidélité méthodologique : La variable `Round_INDICE_SECAL` est calculée par les mêmes équipes techniques du PAM qui ont conçu et validé l'instrument de mesure, garantissant une application rigoureuse et sans ambiguïté des seuils et pondérations officiels [78].

Réduction du risque d’erreur de recodage : La reconstruction manuelle d’un score composite à partir de 18 items de consommation bruts (Section 4.01 du questionnaire) comporte un risque non négligeable d’erreur de correspondance entre groupes alimentaires et items, comme l’illustre la correction apportée à la table de pondération du SCA (Table 4 ci-après).

Cohérence avec les publications officielles : L’utilisation de la classification officielle permet une comparabilité directe avec les statistiques descriptives publiées par le PAM pour l’enquête AGVSAN 2017 [62] (prévalences nationale, urbaine et rurale notamment).

Validation croisée renforcée plutôt qu’affaiblie : Ce choix n’empêche nullement une démarche de contrôle de qualité : une reconstruction indépendante du Score de Consommation Alimentaire (SCA) à partir des items bruts, selon la méthodologie exposée en Section 3.2.1, est conduite en parallèle à des fins de *validation croisée* (Section 4.2.3), permettant de vérifier la cohérence entre la classification officielle et un calcul reproductible indépendant.

4.2.2 Modalités de la variable Round_INDICE_SECAL et dichotomisation

La vérification empirique des labels de valeurs de la variable (`meta.variable_value_labels` sous Python, via `pyreadstat`) confirme que Round_INDICE_SECAL classe chaque ménage selon **quatre modalités**, correspondant au schéma de classification CARI standard du PAM présenté en Section 3.2.2 [79] :

TABLE 3 – Modalités de la variable Round_INDICE_SECAL

Code	Modalité	Statut retenu
1	Sécurité alimentaire	$Y = 0$
2	Sécurité alimentaire limite	$Y = 0$
3	Insécurité alimentaire modérée	$Y = 1$
4	Insécurité alimentaire sévère	$Y = 1$

Justification de la règle de dichotomisation Conformément à la convention de reporting standard du PAM pour ce type de classification CARI [79] — celle-là même qui sous-tend les prévalences nationales et par milieu de résidence citées en Section 2.1 (25,69 % en milieu urbain, 74,70 % en milieu rural, [62]) — les classes *Sécurité alimentaire* et *Sécurité alimentaire limite* sont regroupées comme non vulnérables ($Y = 0$), tandis que les classes *Insécurité alimentaire modérée* et *Insécurité alimentaire sévère* sont regroupées comme vulnérables ($Y = 1$). Ce choix garantit la comparabilité directe des prévalences obtenues avec les statistiques officielles de l’enquête AGVSAN 2017.

La variable dépendante binaire du modèle est ainsi construite comme suit :

$$Y_i = \begin{cases} 1 & \text{si le ménage } i \text{ est classé en insécurité alimentaire modérée ou sévère (codes 3 ou 4)} \\ 0 & \text{si le ménage } i \text{ est classé en sécurité alimentaire ou en sécurité alimentaire limite (codes 1 ou 2)} \end{cases} \quad (4)$$

Traitement spécifique de la classe « Sécurité alimentaire limite » Cette classe intermédiaire désigne des ménages non classés en insécurité au sens strict, mais dont la situation reste précaire et potentiellement instable une distinction analogue à celle opérée par Coates [16] entre sécurité stricte et vulnérabilité marginale (Section 3.1.3). Le regroupement de cette classe avec la *Sécurité alimentaire* (éq. 4) est le choix de référence, mais il n'est pas sans alternative : afin de tester la sensibilité des résultats à ce choix, deux définitions alternatives de Y sont examinées en Section 4.2.4 :

Définition 1 (référence) : $Y = 1$ si code $\in \{3, 4\}$ (insécurité modérée ou sévère) — éq. 4.

Définition 2 (seuil strict) : $Y = 1$ si code = 4 (insécurité sévère uniquement), pour identifier spécifiquement les déterminants des situations les plus critiques.

Définition 3 (seuil élargi) : $Y = 1$ si code $\in \{2, 3, 4\}$ (incluant la sécurité alimentaire limite parmi les situations vulnérables), afin de vérifier si l'intégration de cette classe intermédiaire modifie la hiérarchie des déterminants ou des modèles.

Si les conclusions sur les déterminants significatifs et la hiérarchie des modèles prédictifs restent stables à travers ces trois définitions, la robustesse des résultats est confirmée.

4.2.3 Score de Consommation Alimentaire (SCA) : rappel méthodologique et rôle de validation croisée

Le SCA reste mobilisé dans ce mémoire, non plus comme fondement de la variable dépendante, mais comme **instrument de validation** de la classification officielle retenue. Sa construction suit strictement la méthodologie standardisée du PAM [78] détaillée en Section 3.2.1 : somme pondérée des fréquences de consommation (sur 7 jours) de 8 groupes alimentaires, chaque fréquence de groupe étant le maximum des fréquences des items qui le composent :

$$SCA_i = \sum_{g=1}^8 w_g \cdot f_{gi} \quad (5)$$

avec les poids w_g rappelés en Table 4 — Céréales et tubercules (items 1–4) : 2 ;

Légumineuses et noix (item 5) : 3 ; Légumes (items 6–8) : 1 ; Fruits (items 9–10) : 1 ; Viande, poisson et œufs (items 11, 12, 13, 14, groupe unique) : 4 ; Lait (item 15) : 4 ; Sucre (item 17) : 0,5 ; Huile (item 16) : 0,5 — soit un $SCA_{\max} = 16 \times 7 = 112$; et les seuils standard $SCA < 28$ (pauvre), $28 \leq SCA \leq 42$ (limite), $SCA > 42$ (acceptable).

TABLE 4 – Rappel des groupes alimentaires et pondérations du SCA (cf. Table 3, Section 3.2.1)

Groupe alimentaire	Poids w_g
Céréales et tubercules	2
Légumineuses et noix	3
Légumes	1
Fruits	1
Viande, poisson et œufs	4
Lait et produits laitiers	4
Sucre	0,5
Huile / matières grasses	0,5

4.2.4 Analyse de sensibilité et validation croisée

Deux vérifications complémentaires sont conduites avant de figer la variable dépendante finale :

Validation croisée officielle / reconstruction indépendante : Un tableau croisé entre Round_INDICE_SECAL (dichotomisée selon l'éq. 4) et le SCA reconstruit et dichotomisé selon le seuil standard ($SCA \leq 42$) est produit, accompagné d'un indice de concordance (pourcentage d'accord et statistique Kappa de Cohen). Un fort taux de concordance confirme la fiabilité du recodage effectué sur les items bruts de consommation ; les cas de désaccord sont examinés individuellement pour identifier d'éventuelles erreurs de correspondance code $\rightarrow$ item.

Analyse de sensibilité sur la dichotomisation : Comme détaillé en Section 4.2.2, la robustesse des résultats (déterminants significatifs, hiérarchie des modèles prédictifs) est testée à travers les trois définitions alternatives de Y qui y sont présentées (référence, seuil strict isolant l'insécurité sévère, seuil élargi incluant la sécurité alimentaire limite parmi les situations vulnérables). Si les conclusions restent stables à travers ces trois définitions, la robustesse du choix de dichotomisation est confirmée.

4.2.5 Indicateurs complémentaires de validation

Indice de Stratégies de Survie (ISS/ $rCSI$) L'indice est calculé à partir des 7 stratégies de survie alimentaires enregistrées en **Section 9, question 9.03** du

questionnaire (items Q_9_03_01 à Q_9_03_07) :

$$ISS_i = \sum_{s=1}^7 p_s \cdot d_{si} \quad (6)$$

où $d_{si} \in \{0, \dots, 7\}$ est la fréquence de recours à la stratégie s par le ménage i , et les pondérations p_s sont celles rappelées en Section 4.2.4 du présent mémoire (édition initiale).

Échelle d’Insécurité Alimentaire des Ménages (HFIAS) L’échelle HFIAS (Section 9, question 9.05 du questionnaire) est mobilisée dans les mêmes conditions que précédemment, comme variable de validation croisée uniquement.

Ces deux indicateurs demeurent, comme précisé en Section 4.3.6, **exclus des variables indépendantes** du modèle, pour éviter toute quasi-tautologie statistique avec la variable dépendante.

4.3 Variables indépendantes extraites du questionnaire

Les variables indépendantes sont extraites du questionnaire AGVSAN 2017 et classées selon les cinq capitaux du cadre des Moyens d’Existence Durables [21]. Pour chaque variable, le code de question source, la nature statistique et le traitement prévu sont précisés.

4.3.1 Capital humain (Section 1 – Démographie et éducation)

TABLE 5 – Variables du capital humain extraites de la Section 1

Variable	Code	Modalités / Mesure	Nature	Traitement
Sexe du chef de ménage	1.01	1=Masculin, 2=Féminin	Binaire	Recodage : 1=Masc., 0=Fém.
Âge du chef de ménage	1.02	Âge en années	Continue	Directe + test Box-Tidwell
Ethnie du chef de ménage	1.03	11 groupes ethniques	Polytomique	Variables indicatrices (réf. : Fon)
Statut matrimonial	1.04	4 modalités	Polytomique	Variables indicatrices

Variable	Code	Modalités / Mesure	Nature	Traitement
Niveau d'instruction	1.09	8 niveaux	Polytomique ordinal	0=Aucun, 1=Primaire, 2=Secon- daire+
Taille du ménage	1.08	Somme membres	Discrète	Utilisation directe
Ratio de dépendance	1.08 calculé	$(N_{0-14} + N_{60+})/N_{15-59}$	Continue	Variable construite
Scolarisation enfants 6–14 ans	1.10	Nb enfants scolarisés	Discrète	Taux = scola- risés/total 6–14 ans

Construction du ratio de dépendance : À partir de la question 1.08 qui collecte le nombre de membres par tranche d'âge et par sexe, le ratio de dépendance démographique est calculé :

$$RD_i = \frac{N_{0-14,i}^M + N_{0-14,i}^F + N_{60+,i}^M + N_{60+,i}^F}{N_{15-59,i}^M + N_{15-59,i}^F} \quad (7)$$

Un ratio élevé signifie une forte charge démographique sur les membres actifs du ménage.

4.3.2 Capital physique et habitat (Section 3)

TABLE 6 – Variables du capital physique extraites de la Section 3

Variable	Code	Modalités	Nature	Traitement
Milieu de résidence	0.1.7	1=Urbain, 2=Rural	Binaire	1=Rural, 0=Urbain
Département	0.1.3	12 départements	Polytomique	Indicatrices (réf. : Atlantique)
Composant murs	3.02	8 modalités	Polytomique	1=Matériau dur, 0=Précaire

Variable	Code	Modalités	Nature	Traitement
Composant toit	3.03	8 modalités	Polytomique	1=Tôle/tuile/ dalle, 0=Précaire
Composant sol	3.04	6 modalités	Polytomique	1=Ciment/ carrelage, 0=Terre battue
Source d'éclairage	3.06	9 modalités	Polytomique	1=Électricité/ solaire, 0=Autre
Source d'eau de boisson	3.10	8 modalités	Polytomique	1=Améliorée (1-4+7), 0=Non améliorée
Temps d'accès à l'eau	3.11	5 modalités ordinales	Ordinale	Directe (1=dans la maison à 5=plus d'1h)
Traitement de l'eau	3.12	8 modalités	Polytomique	1=Traitement quelconque, 0=Aucun
Type de toilette	3.13	7 modalités	Polytomique	1=Latrine améliorée, 0=Autre/ Nature

Indice de qualité du logement : Une variable composite est construite en additionnant les trois indicateurs binaires de qualité des matériaux (murs, toit, sol), produisant un score ordinal de 0 à 3.

4.3.3 Capital financier et économique (Sections 5 et 6)

TABLE 7 – Variables du capital financier extraites des Sections 5 et 6

Variable	Code	Modalités / Mesure	Nature	Traitement
Nb membres contribuant aux revenus	5.01	0–99 membres	Discrète	Utilisation directe
Activité principale	5.02	29 codes	Polytomique	6 catégories regroupées
Valeur mensuelle du revenu	5.03	En FCFA	Continue	$\ln(\text{revenu} + 1)$
Diversification des revenus	5.02 calculé	Nb sources	Discrète	0, 1, 2 ou 3 sources
Contribution relative source principale	5.04	Pourcentage (0–100)	Continue	Utilisation directe
Accès au crédit	6.02	0=Non, 1=Oui	Binaire	Utilisation directe
Montant transféré par migrants	2.04	En FCFA	Continue	Log transf. si > 0 + indicatrice
Dépenses alimentaires (30 jours)	6.08–6.09	Somme items	Continue	Log transf.

Regroupement des activités (5.02) : Les 29 codes d'activités sont regroupés en 6 catégories : (1) Agriculture vivrière/de rente (codes 01–02) ; (2) Élevage, pêche, chasse, cueillette (codes 03–08) ; (3) Commerce formel et informel (codes 10–16) ; (4) Salarié, fonctionnaire, travail journalier (codes 17–22) ; (5) Transferts, aides, dons (codes 25–28) ; (6) Autre (codes 09, 19, 24, 29).

4.3.4 Capital naturel et agricole (Sections 7 et 8)

TABLE 8 – Variables du capital naturel extraites des Sections 7 et 8

Variable	Code	Modalités / Mesure	Nature	Traitement
Pratique de l'agriculture	7.01	0=Non, 1=Oui	Binaire	Utilisation directe
Mode d'accès à la terre	7.03	6 modalités	Polytomique	Propr./fam., loc./autre
Femmes propriétaires de terre	7.04	0=Non, 1=Oui	Binaire	Utilisation directe
Superficie emblavée	7.05	6 classes (en ha)	Ordinale	Directe (1=moins de 1 ha à 6=5 ha et plus)
Pratique cultures irriguées	7.06	0=Non, 1=Oui	Binaire	Utilisation directe
Utilisation semences améliorées	7.12	0=Non, 1=Oui	Binaire	Utilisation directe
Utilisation engrais chimiques	7.12	0=Non, 1=Oui	Binaire	Utilisation directe
Mois de couverture par stock vivrier	7.11	0–12 mois	Discrète	Nb de mois de couverture
Ménage propriétaire d'animaux	8.01	0=Non, 1=Oui	Binaire	Utilisation directe
Valeur totale du cheptel	8.02	Nb têtes × type	Continue	Indice TLU

Construction de l'indice TLU : À partir de la question 8.02 qui enregistre le nombre de têtes de 9 types d'animaux, un indice standardisé du capital bétail est calculé selon les coefficients TLU standards [26] :

$$TLU_i = 0,7N_{\text{bov}} + 0,1(N_{\text{cap}} + N_{\text{ovi}}) + 0,2N_{\text{porc}} + 0,5(N_{\text{âne}} + N_{\text{chev}}) + 0,01N_{\text{vol}} + 0,1N_{\text{lap}} \quad (8)$$

4.3.5 Capital social et chocs (Sections 9 et 10)

TABLE 9 – Variables du capital social extraites des Sections 9 et 10

Variable	Code	Modalités / Mesure	Nature	Traitement
Ménage ayant subi un choc	9.01	0=Non, 1=Oui	Binaire	Utilisation directe
Type de choc principal	9.02	26 codes	Polytomique	4 catégories : Climatique, Sanitaire, Économique, Autre
Capacité de relèvement	9.02.3	1=Pas du tout à 3=Entièrement	Ordinale	Utilisation directe
Indice Stratégies de Survie	9.03 calculé	Score 0–21	Continue	<i>Exclu des prédicteurs variable de validation croisée uniquement (voir §4.2.4)</i>
Vente d'actifs productifs	9.04 items 2,3	0=Non, 1=Oui	Binaire	Utilisation directe
Score HFIAS	9.05	Score 0–27	Continue	Variable de validation uniquement
Assistance reçue	10.1	0=Non, 1=Oui	Binaire	Utilisation directe
Type d'assistance alimentaire	10.2	0=Non, 1=Oui	Binaire	Utilisation directe

4.3.6 Tableau récapitulatif des variables retenues pour la modélisation

TABLE 10 – Récapitulatif des variables indépendantes retenues

Variable	Code source	Nature finale	Capital SLF	Hyp.
Sexe chef de ménage	1.01	Binaire	Humain	H_1
Âge chef de ménage	1.02	Continue	Humain	H_1

Variable	Code source	Nature finale	Capital SLF	Hyp.
Niveau d'instruction	1.09	Ordinale (3 niveaux)	Humain	H_1
Taille du ménage	1.08	Discrète	Humain	H_1
Ratio de dépendance	1.08 calculé	Continue	Humain	H_1
Milieu de résidence	0.1.7	Binaire	Physique	H_1
Département	0.1.3	Polytomique (12)	Physique	H_3
Indice qualité logement	3.02–3.04	Ordinal (0–3)	Physique	H_1
Accès eau améliorée	3.10	Binaire	Physique	H_1
Accès électricité	3.06	Binaire	Physique	H_1
Type de toilette	3.13	Binaire	Physique	H_1
Activité principale	5.02	Polytomique (6)	Financier	H_1
Log-revenu mensuel	5.03	Continue	Financier	H_1
Diversification revenus	5.02 calculé	Discrète (0–3)	Financier	H_1
Accès au crédit	6.02	Binaire	Financier	H_1
Pratique agriculture	7.01	Binaire	Naturel	H_1
Sécurité foncière	7.03	Binaire	Naturel	H_1
Superficie emblavée	7.05	Ordinale (6 classes)	Naturel	H_1
Cultures irriguées	7.06	Binaire	Naturel	H_1
Semences améliorées	7.12	Binaire	Naturel	H_1
Mois de couverture stocks	7.11	Discrète (0–12)	Naturel	H_1
Possession bétail (TLU)	8.02 calculé	Continue	Naturel	H_1
Choc subi	9.01	Binaire	Social	H_1
Type de choc	9.02	Polytomique (4)	Social	H_1
Indice de survie (ISS)	9.03 calculé	Continue	Social	H_1
Assistance alimentaire	10.1–10.2	Binaire	Social	H_1

Exclusion de l'ISS et du HFIAS des prédicteurs Il convient de souligner que l'ISS et le HFIAS, bien que calculés à partir du questionnaire, sont **délibérément exclus des variables indépendantes** retenues pour la modélisation (Table 10). Ces deux indices

mesurent en effet des comportements et perceptions directement liés à la consommation alimentaire des ménages : les inclure comme prédicteurs du SCA dichotomisé introduirait une quasi-tautologie statistique, dans la mesure où un ménage qui réduit ses repas ou recourt à des stratégies de survie alimentaires (mesurées par l'ISS) présente presque mécaniquement un SCA dégradé. Ces deux indicateurs sont donc réservés à leur rôle de *variables de validation croisée* de la variable dépendante, conformément à leur usage documenté dans la littérature [13].

4.4 Analyse descriptive et tests statistiques pré-estimation

Cette section présente, pour six variables jugées centrales dans le cadre conceptuel retenu (Section 3.3) la situation alimentaire des ménages (variable dépendante), la taille du ménage, le revenu, l'âge du chef de ménage, son niveau d'instruction, et l'accès du ménage au crédit une double analyse : **univariée** (description de la distribution de chaque variable prise isolément) puis **bivariée** (association statistique de chaque variable avec le statut de sécurité alimentaire Y). Chaque analyse combine systématiquement une *approche tableau* (statistiques ou tableaux de contingence) et une *approche graphique*, conformément aux standards de présentation d'une analyse exploratoire rigoureuse. L'analyse est ensuite étendue, de façon plus synthétique, à l'ensemble des variables indépendantes retenues (Table 10).

4.4.1 Variables focales et nature statistique

TABLE 11 – Variables focales de l'analyse descriptive

Variable	Code source	Nature	Rôle
Situation alimentaire (Y)	Round_INDICE_SEBA	Binaire (dichotomisée)	Variable dépendante
Taille du ménage	Q_1_08_tcalculable	Discrete	Capital humain
Revenu mensuel du ménage	Q_5_03_1_1	Continue (asymétrique)	Capital financier
Âge du chef de ménage	Q_1_02	Continue	Capital humain
Niveau d'instruction du CM	Q_1_09	Polytomique ordinaire	Capital humain
Accès au crédit	Q_6_02	Binaire	Capital financier

4.4.2 Analyse univariée

a) Répartition de la situation alimentaire des ménages (Y) *Approche tableau.*
Un tableau de fréquences absolues et relatives présente la répartition des ménages

entre sécurité et insécurité alimentaire, au niveau national puis stratifiée par milieu de résidence (urbain/rural) et par département, afin de situer la prévalence observée par rapport aux chiffres de référence du rapport AGVSAN 2017 (25,69 % en milieu urbain, 74,70 % en milieu rural selon [62] — cf. Section 2.1).

Approche graphique. Un diagramme en barres (ou en secteurs) présente la proportion de ménages en sécurité/insécurité alimentaire au niveau national, complété par un diagramme en barres empilées ou groupées par département, permettant une première lecture visuelle des disparités géographiques évoquées dans la problématique.

b) Répartition de la taille des ménages *Approche tableau.* Statistiques descriptives complètes : moyenne, médiane, écart-type, coefficient de variation, minimum, maximum, percentiles (P_{10} , P_{25} , P_{75} , P_{90}), calculées globalement et stratifiées par milieu de résidence.

Approche graphique. Histogramme de la distribution de la taille du ménage, complété par une boîte à moustaches comparant les distributions urbaine et rurale.

c) Distribution du revenu *Approche tableau.* Statistiques descriptives (moyenne, médiane, écart-type, asymétrie/*skewness*) calculées à la fois sur l'échelle brute (Francs CFA) et sur l'échelle log-transformée ($\ln(\text{revenu} + 1)$), cette dernière étant celle effectivement mobilisée dans la modélisation (Section 4.3.3) en raison de l'asymétrie attendue de la distribution des revenus.

Approche graphique. Histogramme du revenu brut (mettant en évidence l'asymétrie à droite typique des données de revenu) et histogramme du revenu log-transformé (permettant de juger visuellement du rapprochement vers une distribution symétrique justifiant la transformation).

d) Distribution de l'âge du chef de ménage *Approche tableau.* Statistiques descriptives complètes (mêmes indicateurs que pour la taille du ménage), avec un tableau de répartition par tranches d'âge usuelles (moins de 30 ans, 30–44 ans, 45–59 ans, 60 ans et plus) pour faciliter la lecture.

Approche graphique. Histogramme de la distribution de l'âge, avec superposition d'une estimation de densité par noyau (*kernel density estimate*).

e) Répartition du niveau d'instruction *Approche tableau.* Tableau de fréquences absolues et relatives pour chacune des modalités de la variable Q_1_09 (Aucun, Alphabétisation, Primaire, Secondaire, Supérieur, Coursus arabe, École coranique, Autre), puis pour la version recodée en trois niveaux retenue pour la modélisation (0 = Aucun ; 1 = Primaire ; 2 = Secondaire et plus, cf. Table 5).

Approche graphique. Diagramme en barres de la répartition des ménages selon le niveau d'instruction du chef de ménage (modalités originales, triées par fréquence décroissante).

f) Répartition des ménages ayant accès au crédit *Approche tableau.* Tableau de fréquences (nombre et proportion de ménages ayant emprunté au cours des 12 derniers mois, variable Q_6_02), stratifié par milieu de résidence.

Approche graphique. Diagramme en barres comparant la proportion de ménages ayant accès au crédit entre milieu urbain et milieu rural.

4.4.3 Test de normalité des variables continues

Objectif : Vérifier si la taille du ménage, le revenu (brut et log-transformé) et l'âge du chef de ménage suivent une distribution normale, afin d'orienter le choix entre tests paramétriques et non paramétriques lors de l'analyse bivariée (Section 4.4.4).

H_0 : La variable suit une loi normale $\mathcal{N}(\mu, \sigma^2)$.

Statistique : $D_n = \sup_{x \in \mathbb{R}} |F_n(x) - \Phi\left(\frac{x - \bar{x}}{s}\right)|$ (test de Kolmogorov-Smirnov), où $F_n(x)$ est la fonction de répartition empirique et Φ la fonction de répartition normale standard.

Règle de décision : $p > 0,05$: normalité acceptable, tests paramétriques applicables.

$p \leq 0,05$: normalité rejetée, recours au test non paramétrique de Mann-Whitney.

Précaution sur la taille d'échantillon : Avec $n \approx 15\,000$, le test KS présente une puissance statistique très élevée et rejettera quasi systématiquement H_0 même pour des écarts mineurs à la normalité. La décision est donc complétée par un examen graphique (histogrammes et QQ-plots de la Section 4.4.2) et par les coefficients d'asymétrie (*skewness*) et d'aplatissement (*kurtosis*), plutôt que fondée sur la seule valeur du p .

Implémentation : `scipy.stats.kstest()` et `scipy.stats.shapiro()` en complément, sous Python.

4.4.4 Analyse bivariée : croisement de chaque variable focale avec la variable dépendante

Chaque variable focale est croisée avec Y selon le test adapté à sa nature statistique, présenté systématiquement selon le canevas : objectif, hypothèse nulle, statistique de test, règle de décision, puis complété par un tableau croisé et une représentation graphique comparative.

b'. Taille du ménage $\times$ Situation alimentaire

Objectif : Comparer la taille moyenne des ménages entre le groupe en sécurité alimentaire ($Y = 0$) et le groupe en insécurité alimentaire ($Y = 1$).

H_0 : $\mu_{\text{taille}, Y=0} = \mu_{\text{taille}, Y=1}$ (test t) ou distributions identiques dans les deux groupes (test de Mann-Whitney, si normalité rejetée).

Procédure : Vérification préalable de l'homoscédasticité par le test de Levene ; test t de Student (version de Welch si $p_{\text{Levene}} \leq 0,05$) ou test U de Mann-Whitney selon le résultat du test de normalité (Section 4.4.2).

Règle de décision : $p < 0,05$: différence significative.

Présentation : Tableau comparant moyenne, médiane et écart-type de la taille du ménage par statut Y ; boîte à moustaches comparative (taille du ménage selon Y).

Implémentation : `scipy.stats.levene()`, `scipy.stats.ttest_ind()`, `scipy.stats.mannwhitn`

c'. Revenu $\times$ Situation alimentaire

Objectif : Comparer le niveau de revenu (log-transformé) entre ménages en sécurité et en insécurité alimentaire hypothèse attendue d'un revenu significativement inférieur parmi les ménages en insécurité alimentaire, cohérente avec l'approche des pièges à pauvreté [5] discutée en Section 3.3.3.

H_0 / **Procédure** / **Règle :** Identiques au point précédent, appliquées à $\ln(\text{revenu} + 1)$.

Présentation : Tableau comparatif des statistiques de revenu par statut Y (échelle brute *et* log) ; boîte à moustaches du revenu log-transformé selon Y .

d'. Âge du chef de ménage $\times$ Situation alimentaire

Objectif / H_0 / **Procédure** / **Règle :** Identiques au point (b'), appliqués à l'âge du chef de ménage.

Présentation : Tableau comparatif ; boîte à moustaches de l'âge selon Y ; tableau croisé complémentaire entre tranches d'âge usuelles et statut Y (fréquences et pourcentages en ligne).

e'. Niveau d'instruction $\times$ Situation alimentaire

Objectif : Tester l'existence d'une association statistique entre le niveau d'instruction du chef de ménage (recodé en 3 niveaux) et le statut de sécurité alimentaire.

H_0 : Les deux variables sont statistiquement indépendantes.

Statistique : $\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi_{(r-1)(c-1)}^2$

Mesure d'effet : V de Cramér = $\sqrt{\chi^2 / (n \cdot \min(r - 1, c - 1))}$.

Règle de décision : $p < 0,05$: association significative. Conditions de validité : $E_{ij} \geq 5$ dans au moins 80 % des cellules ; à défaut, test exact de Fisher.

Présentation : Tableau croisé (niveau d’instruction $\times Y$) en effectifs et en pourcentages en ligne ; diagramme en barres groupées (proportion d’insécurité alimentaire par niveau d’instruction), attendu décroissant avec le niveau d’instruction conformément à la littérature [55].

Implémentation : `scipy.stats.chi2_contingency()`, `scipy.stats.fisher_exact()` en cas de violation des effectifs théoriques minimaux.

f. Accès au crédit $\times$ Situation alimentaire

Objectif / H_0 / Statistique / Règle : Identiques au point (e’), appliqués à la variable binaire d’accès au crédit (Q_6_02) — cas particulier d’un tableau 2×2 , pour lequel le test exact de Fisher est utilisé par défaut si un effectif théorique est inférieur à 5.

Présentation : Tableau croisé 2×2 (accès au crédit $\times Y$) et odds ratio brut associé (avec intervalle de confiance à 95 %) ; diagramme en barres comparant la prévalence d’insécurité alimentaire entre ménages ayant et n’ayant pas accès au crédit.

Synthèse et correction pour comparaisons multiples L’ensemble des tests bivariés conduits dans cette section (les six variables focales, puis l’ensemble des variables indépendantes de la Table 10 selon la même procédure de manière plus synthétique) fait l’objet d’une correction de type Benjamini-Hochberg (contrôle du *False Discovery Rate*) sur l’ensemble des p -valeurs obtenues, avant interprétation, afin de limiter l’inflation du risque d’erreur de type I inhérente aux tests multiples. Un tableau de synthèse récapitule, pour chaque variable : le test utilisé, la statistique, la p -valeur brute, la p -valeur ajustée (FDR), et la conclusion retenue.

Implémentation : `statsmodels.stats.multitest.multipletests(method="fdr_bh")`.

4.4.5 Détection de la multicolinéarité

Objectif : Identifier les redondances informationnelles entre prédicteurs susceptibles de gonfler les variances des estimateurs du modèle Logit.

Méthode : Facteur d’Inflation de la Variance (VIF) : $\text{vif}_j = 1/(1 - R_j^2)$, où R_j^2 est le coefficient de détermination de la régression de X_j sur l’ensemble des autres prédicteurs.

Règle : $\text{vif}_j \in (1, 5)$: acceptable ; $\text{vif}_j \in (5, 10)$: modérée (surveillance) ; $\text{vif}_j > 10$: sévère (variable à transformer ou exclure).

Application attendue : Une colinéarité est attendue entre le log-revenu et la diversification des revenus, entre l’indice de qualité du logement et l’accès à l’électricité, et entre la superficie cultivée et la pratique de l’agriculture.

Cas des variables catégorielles (GVIF) : Le VIF classique n’étant valide que pour des prédictors continus, le Facteur d’Inflation de la Variance Généralisé (GVIF) est calculé pour les variables polytomiques (ethnie, département, niveau d’instruction, type de choc) et interprété via sa forme normalisée $\text{gvif}^{1/(2df)}$, comparable au seuil du VIF usuel [29].

Implémentation : Calcul manuel par régression successive de chaque prédicteur continu sur les autres (`statsmodels.stats.outliers_influence.variance_inflation_factor`) appliqué à une matrice de conception numérisée (*one-hot encoding* via `pandas.get_dummies()`).

4.4.6 Gestion des données manquantes

- **Moins de 5 % de valeurs manquantes :** imputation par la médiane (continues) ou le mode (catégorielles).
- **5–15 % de valeurs manquantes :** imputation par k -plus proches voisins (k -NN, $k = 5$).
- **Plus de 15 % de valeurs manquantes :** exclusion de la variable ou création d’une modalité “Non renseigné” si la donnée manquante est informative.
- **Variable dépendante Y :** tout ménage pour lequel `Round_INDICE_SECAL` est manquante est exclu de l’analyse.

4.5 Modélisation économétrique et prédictive

4.5.1 Partition stratifiée de l’échantillon

La base de données est partitionnée de manière aléatoire avec une graine fixée (`random_state=42`) en un *échantillon d’apprentissage* (70 %) et un *échantillon test* (30 %). Les tailles exactes seront déterminées après la procédure de nettoyage décrite en Section 4.1.2. La partition est réalisée avec *stratification sur Y* via `sklearn.model_selection.train_test_split(..., stratify=y, random_state=42)`, afin de maintenir la même proportion de ménages en insécurité alimentaire dans les deux sous-échantillons. Toutes les opérations d’estimation, de sélection des variables et d’optimisation des hyperparamètres sont conduites exclusivement sur l’échantillon d’apprentissage. L’échantillon test est réservé à l’évaluation finale hors-échantillon.

Reproductibilité et graines aléatoires Au-delà de la partition initiale, plusieurs étapes ultérieures du pipeline sont elles-mêmes stochastiques : le sur-échantillonnage SMOTE, le *bagging* du *Random Forest*, le *sampling* de *XGBoost* (`subsample`, `colsample_bytree`) et le partitionnement des plis de validation croisée. Une graine

unique (`RANDOM_STATE = 42`) est fixée et systématiquement transmise en argument (`random_state=RANDOM_STATE`) à chaque fonction concernée, de sorte que l'intégralité du pipeline soit reproductible à l'identique d'une exécution à l'autre.

Prise en compte du plan de sondage dans les statistiques descriptives et les tests bivariés Par cohérence avec l'intégration des pondérations d'enquête dans les modèles prédictifs (Sections 4.5.4 et 4.5.5) et dans la cartographie (Section 4.9), les statistiques descriptives univariées (moyennes, proportions) et les tests bivariés de la Section 4.4 sont recalculés en tenant compte du plan de sondage complexe (poids, strates, grappes) via le package `samplics`, équivalent Python le plus proche du package `survey` de référence en R [45]. Les moyennes et proportions pondérées sont obtenues via les estimateurs de `samplics.TaylorEstimator`, et les tests d'association (analogues design-based du χ^2 et du test t) via les méthodes de linéarisation de Taylor qui y sont implémentées. *Limite reconnue* : l'écosystème Python pour l'analyse de données d'enquête à plan complexe reste moins mature que le package `survey` sous R ; les tests bivariés non disponibles nativement dans `samplics` sont, à défaut, calculés à la fois en version non pondérée (`scipy.stats`) et en version pondérée par repondération simple des effectifs, avec signalement explicite du choix retenu dans le rapport de résultats.

4.5.2 Gestion du déséquilibre de classes

Nous privilégions en premier lieu le **class weighting** plutôt que la technique SMOTE [14], pour deux raisons : (i) le class weighting ne génère pas de données synthétiques artificielles susceptibles de biaiser la distribution des prédicteurs ; (ii) il est directement intégrable dans les fonctions d'entraînement via `scale_pos_weight = nY=0/nY=1` pour `XGBoost` et `class_weight="balanced"` (ou un dictionnaire de poids explicite) pour `sklearn.ensemble.RandomForestClassifier`. La technique SMOTE, implémentée via `imblearn.over_sampling.SMOTE(random_state=42)` du package `imbalanced-learn`, sera néanmoins testée comme alternative et les résultats comparés dans la section résultats. *Remarque* : la prévalence exacte de $Y = 1$ dans l'échantillon (potentiellement majoritaire au vu des taux nationaux d'insécurité alimentaire rapportés en Section 2.1) sera vérifiée empiriquement en premier lieu, afin de confirmer la nécessité et le sens du rééquilibrage à appliquer.

4.5.3 Modèle 1 : Régression Logistique Binaire

Présentation et justification La régression logistique binaire est un modèle de la famille des Modèles Linéaires Généralisés (GLM) adapté à une variable dépendante dichotomique [51]. Il est retenu comme *modèle de référence explicatif* pour trois raisons : (i) il produit des rapports de cotes (*Odds Ratios*) directement interprétables qui quan-

tifient l'effet de chaque déterminant sur le risque d'insécurité alimentaire, répondant à l'OS1 ; (ii) il bénéficie d'une théorie asymptotique bien développée pour les tests d'inférence sur les coefficients [37] ; (iii) il constitue le modèle de référence (*benchmark*) contre lequel les performances prédictives des algorithmes ML sont comparées.

Fondement théorique Le modèle postule $P(Y_i = 1|\mathbf{X}_i) = \pi_i$ avec la fonction de lien logistique :

$$\pi_i = \frac{1}{1 + \exp\left(-\left(\beta_0 + \sum_{j=1}^k \beta_j X_{ji}\right)\right)} = \sigma(\mathbf{X}_i^\top \boldsymbol{\beta}) \quad (9)$$

La transformation logit linéarise la relation :

$$\text{logit}(\pi_i) = \ln\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} \quad (10)$$

L'*Odds Ratio* associé à X_j est $\text{OR}_j = \exp(\hat{\beta}_j)$: $\text{OR}_j > 1$ augmente le risque d'insécurité alimentaire ; $\text{OR}_j < 1$ le réduit, toutes choses égales par ailleurs.

Estimation par maximum de vraisemblance (MLE) Les paramètres $\boldsymbol{\beta}$ sont estimés en maximisant la log-vraisemblance :

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n [Y_i \ln(\hat{\pi}_i) + (1 - Y_i) \ln(1 - \hat{\pi}_i)] \quad (11)$$

L'algorithme de Newton-Raphson converge vers l'estimateur $\hat{\boldsymbol{\beta}}$:

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} + [\mathbf{I}(\boldsymbol{\beta}^{(t)})]^{-1} \mathbf{s}(\boldsymbol{\beta}^{(t)}) \quad (12)$$

où $\mathbf{s}(\boldsymbol{\beta}) = \partial\ell/\partial\boldsymbol{\beta}$ est le vecteur score et $\mathbf{I}(\boldsymbol{\beta}) = -\partial^2\ell/\partial\boldsymbol{\beta}\partial\boldsymbol{\beta}^\top$ la matrice d'information de Fisher.

Sélection des variables

$$\text{aic} = 2k - 2\ell(\hat{\boldsymbol{\beta}}) \quad (13)$$

La sélection des variables par recherche pas à pas (*stepwise*) minimisant l'AIC est une pratique répandue, mais elle a fait l'objet de critiques méthodologiques sérieuses : Harrell [32] souligne notamment qu'elle tend à gonfler artificiellement la significativité apparente des coefficients retenus et à produire des modèles instables (forte variabilité de l'ensemble de variables sélectionnées selon l'échantillon). Compte tenu de cette réserve, une approche de **régularisation Elastic-Net** (pénalisation combinée L_1/L_2) sera privilégiée comme méthode principale de sélection/régularisation des variables du

Logit, via `sklearn.linear_model.LogisticRegressionCV(penalty="elasticnet", solver="saga", l1_ratios=[.1,.5,.7,.9,.99,1], cv=10)`. Le modèle final, une fois les variables stabilisées par cette procédure, est réestimé sans pénalisation via `statsmodels.api.GLM(family=sm.families.Binomial())` afin d'obtenir l'inférence classique (erreurs-types, intervalles de confiance, p -valeurs, AIC) nécessaire à l'interprétation en Odds Ratios. La sélection *stepwise* classique par AIC (recherche bidirectionnelle implémentée manuellement par boucle sur `statsmodels`, aucun équivalent direct de `step()` de R n'existant nativement en Python) est conservée uniquement à titre de comparaison et de robustesse.

Qualité d'ajustement global : pseudo- R^2 Contrairement au modèle linéaire classique, le Logit ne dispose pas d'un R^2 au sens strict. Trois pseudo- R^2 complémentaires sont néanmoins rapportés pour caractériser la qualité d'ajustement globale du modèle, chacun avec ses limites d'interprétation :

Pseudo- R^2 de McFadden :

$$R_{\text{McFadden}}^2 = 1 - \frac{\ell(\hat{\beta}_{\text{complet}})}{\ell(\hat{\beta}_{\text{nul}})} \quad (14)$$

où $\ell(\hat{\beta}_{\text{complet}})$ et $\ell(\hat{\beta}_{\text{nul}})$ sont respectivement les log-vraisemblances du modèle complet et du modèle nul (constante seule). Des valeurs entre 0,2 et 0,4 sont usuellement considérées comme indiquant un très bon ajustement pour ce pseudo- R^2 [McFadden1974], des valeurs nettement inférieures à celles attendues pour un R^2 de régression linéaire classique.

Pseudo- R^2 de Cox et Snell : $R_{\text{CS}}^2 = 1 - \left(\frac{L_{\text{nul}}}{L_{\text{complet}}} \right)^{2/n}$, où L désigne la vraisemblance (non log). Limite documentée : ce pseudo- R^2 ne peut atteindre la valeur 1 même pour un ajustement parfait.

Pseudo- R^2 de Nagelkerke : Version normalisée du précédent, $R_{\text{Nag}}^2 = R_{\text{CS}}^2 / R_{\text{CS,max}}^2$, corrigeant cette limite pour permettre une lecture comprise entre 0 et 1.

Implémentation : Ces trois indicateurs sont disponibles directement via les attributs du résultat ajusté sous `statsmodels` (`.prsquared` pour McFadden dans l'API Logit) ou calculés manuellement à partir de `.llf` et `.llnull` pour un modèle GLM Binomial.

Ces pseudo- R^2 sont rapportés *en complément*, et non en remplacement, du test de rapport de vraisemblance global et du critère AIC présentés dans les paragraphes suivants, ces derniers demeurant les critères de référence pour juger de la significativité et de la qualité d'ajustement du modèle Logit.

Tests pré-estimation spécifiques au Logit

Test de Box-Tidwell (linéarité dans le logit)

Objectif : Vérifier que la relation entre chaque prédicteur continu et le logit de π_i est bien linéaire.

Procédure : Ajouter les termes $X_j \cdot \ln(X_j)$ au modèle et tester leur significativité.

$H_0 : \beta_{X_j \ln X_j} = 0$ (linéarité vérifiée).

Règle : $p < 0,05$: relation non linéaire dans le logit ; transformation nécessaire (catégorisation en quartiles ou spline cubique).

Implémentation : Aucun équivalent direct du package `car` n'existant en Python, le test est implémenté manuellement : ajout du terme $X_j \ln(X_j)$ comme régresseur supplémentaire dans un modèle `statsmodels.api.GLM`, puis test de Wald sur son coefficient via l'attribut `.pvalues` du résultat ajusté.

Détection des observations influentes

Méthodes : Résidus de déviance studentisés et Distance de Cook D_i .

Règles : Résidu studentisé > 2 en valeur absolue : observation suspecte. $D_i > 4/n$: observation très influente. Une analyse de sensibilité (estimation sans les observations influentes) est conduite pour vérifier la stabilité des coefficients.

Test de rapport de vraisemblance global

$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$ (le modèle complet n'apporte pas d'information au-delà de la constante).

Statistique : $\Lambda = -2[\ell(\hat{\beta}_{\text{nul}}) - \ell(\hat{\beta}_{\text{complet}})] \sim \chi_k^2$ sous H_0 .

Règle : $p < 0,05$: modèle globalement significatif.

Test d'adéquation de Hosmer-Lemeshow (post-estimation)

Objectif : Évaluer si les probabilités prédites $\hat{\pi}_i$ sont bien calibrées aux fréquences observées.

Procédure : Les n observations sont classées par $\hat{\pi}_i$ croissante et regroupées en $g = 10$ déciles. Dans chaque groupe j , on compare l'effectif observé O_j et attendu $E_j = \sum_{i \in j} \hat{\pi}_i$.

H_0 : Le modèle est bien calibré.

Statistique : $\hat{H} = \sum_{j=1}^g \frac{(O_j - n_j \hat{\pi}_j)^2}{n_j \hat{\pi}_j (1 - \hat{\pi}_j)} \sim \chi_{g-2}^2$ sous H_0 .

Règle : $p > 0,05$: bon ajustement.

Implémentation : Aucun package Python de référence n'implémentant nativement ce test (contrairement à `ResourceSelection` sous R), il est codé manuellement :

découpage des probabilités prédites en déciles via `pandas.qcut()`, agrégation des effectifs observés/attendus par groupe, puis calcul de la statistique du chi-deux et de sa p -valeur via `scipy.stats.chi2.sf()`. Cette même fonction est réutilisée pour les trois modèles (Section 4.8.2).

4.5.4 Modèle 2 : Random Forest

Présentation et justification Le *Random Forest* [10] est une méthode ensembliste non paramétrique qui combine B arbres de décision entraînés sur des sous-échantillons bootstrap et des sous-ensembles aléatoires de prédicteurs. Sa robustesse à la multicolinéarité, sa capacité à capturer des interactions complexes entre déterminants sans spécification préalable, et la disponibilité de mesures d'importance des variables en font un modèle particulièrement adapté à notre problème.

Algorithme détaillé

Critère de partitionnement – Impureté de Gini

$$G_m = 1 - \sum_{k \in \{0,1\}} \hat{p}_{mk}^2 \quad (15)$$

où $\hat{p}_{mk}$ est la proportion d'observations de la classe k dans le nœud m . La division optimale au nœud m maximise $\Delta G = G_m - (n_L/n_m)G_L - (n_R/n_m)G_R$.

Construction de la forêt Pour $b = 1, \dots, B$:

1. **Bagging** : Tirer un échantillon bootstrap $\mathcal{D}_b$ de taille n avec remise. Les $\approx n/3$ observations non tirées forment l'échantillon OOB de l'arbre b .
2. **Randomisation** : À chaque nœud, sélectionner aléatoirement $m = \lfloor \sqrt{p} \rfloor$ prédicteurs parmi les p disponibles (avec $p \approx 26$, $m \approx 5$).
3. **Croissance** : Faire croître l'arbre T_b jusqu'à sa taille maximale sans élagage.

Prédiction

$$\hat{P}(Y_i = 1 | \mathbf{x}_i) = \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{T_b(\mathbf{x}_i) = 1\} \quad (16)$$

Optimisation des hyperparamètres Validation croisée K -fold par grappes ($K = 10$) avec Grid Search sur l'échantillon d'apprentissage :

n_estimators (B) : $\{300, 500, 1000\}$. Retenu : valeur à partir de laquelle l'erreur OOB (`oob_score=True`) se stabilise.

max_features (m) : $\{2, \lfloor \sqrt{p} \rfloor, \lfloor p/3 \rfloor\} = \{2, 5, 8\}$.

min_samples_leaf : $\{1, 5, 10\}$.

Intégration des pondérations d'enquête dans le *Random Forest* Les pondérations d'échantillonnage sont intégrées via l'argument `sample_weight` de la méthode `.fit()` de `sklearn.ensemble.RandomForestClassifier`, qui pondère à la fois les tirages bootstrap et le calcul de l'impureté de Gini proportionnellement aux poids d'enquête, conformément à l'esprit de la recommandation de Lumley et Scott [45] pour les analyses ML sur données d'enquêtes complexes.

Importance des variables

Mean Decrease in Accuracy (MDA) : La valeur de la variable X_j est permutée aléatoirement dans l'échantillon OOB. La dégradation de l'accuracy mesure l'importance de X_j . Cette mesure est cependant biaisée en faveur des variables à haute cardinalité [72].

Mean Decrease in Gini (MDG) : Somme des réductions d'impureté de Gini engendrées par les divisions sur X_j , moyennée sur tous les arbres. Biaisée en faveur des variables continues [72].

Valeurs SHAP : Mesure d'importance non biaisée, décrite dans la sous-section dédiée ci-après.

4.5.5 Modèle 3 : XGBoost (*eXtreme Gradient Boosting*)

Présentation et justification *XGBoost* [15] est une implémentation optimisée du Gradient Boosting [30] qui construit des arbres *séquentiels*, chaque nouvel arbre corrigeant les erreurs résiduelles du modèle précédent. Sa régularisation explicite $\Omega(f_k) = \gamma T + \frac{1}{2}\lambda\|\mathbf{w}\|^2$ le distingue du Gradient Boosting classique et le rend robuste au surapprentissage.

Algorithme et fonction objectif La prédiction est une somme additive de K arbres :

$$\hat{y}_i^{(K)} = \sum_{k=1}^K f_k(\mathbf{x}_i) \quad (17)$$

À chaque étape k , l'arbre f_k est obtenu en minimisant (développement de Taylor du second ordre) :

$$\mathcal{L}^{(k)} \approx \sum_{i=1}^n \left[g_i f_k(\mathbf{x}_i) + \frac{1}{2} h_i f_k^2(\mathbf{x}_i) \right] + \underbrace{\gamma T + \frac{1}{2}\lambda\|\mathbf{w}\|^2}_{\Omega(f_k)} \quad (18)$$

où $g_i = \partial_{\hat{y}^{(k-1)}} \ell(Y_i, \hat{y}^{(k-1)})$ est le gradient de premier ordre et $h_i = \partial_{\hat{y}^{(k-1)}}^2 \ell(Y_i, \hat{y}^{(k-1)})$ le gradient de second ordre de la fonction de perte binaire $\ell(Y_i, \hat{y}) = -[Y_i \ln \sigma(\hat{y}) + (1 -$

$Y_i) \ln(1 - \sigma(\hat{y}))]$.

La probabilité prédite est :

$$\hat{P}(Y_i = 1|\mathbf{x}_i) = \sigma\left(\sum_{k=1}^K f_k(\mathbf{x}_i)\right) = \frac{1}{1 + e^{-\sum_k f_k(\mathbf{x}_i)}} \quad (19)$$

Optimisation des hyperparamètres Validation croisée K -fold par grappes ($K = 10$) avec Grid Search :

num_boost_round : Avec arrêt précoce (`early_stopping_rounds=50`) sur un sous-échantillon de validation interne (15 % de l'apprentissage), via l'API native `xgboost.train()` du package Python `xgboost` (même bibliothèque C++ sous-jacente qu'en R, seule l'interface change).

max_depth : {3, 5, 7}.

eta (learning rate) : {0,01; 0,05; 0,1}.

subsample : {0,7; 0,8; 1,0}.

colsample_bytree : {0,7; 0,8; 1,0}.

γ (**gamma**) : {0; 0,1; 0,5}.

λ (**lambda**) : {0,5; 1; 2}.

scale_pos_weight : $= n_{Y=0}/n_{Y=1}$.

Remarque sur le volume de calcul : la grille complète ci-dessus représente $3^6 = 729$ combinaisons d'hyperparamètres, à multiplier par les $K = 10$ plis de la validation croisée par grappes, soit environ 7300 entraînements. Si le temps de calcul disponible ne permet pas un *grid search* exhaustif (`sklearn.model_selection.GridSearchCV`), un *random search* tirant un sous-ensemble de combinaisons (`sklearn.model_selection.RandomizedSearchCV`) [7] sera utilisé en alternative, cette approche étant reconnue comme statistiquement équivalente pour un budget de calcul donné.

Encodage des variables catégorielles pour *XGBoost* Contrairement au *Random Forest* sous R qui gère nativement les facteurs, l'implémentation Python de *XGBoost* (comme celle de `scikit-learn`) requiert une matrice de conception entièrement numérique. Les variables polytomiques (ethnie, département, activité principale, type de choc) sont donc converties par encodage disjonctif complet (*one-hot encoding*) via `pandas.get_dummies(drop_first=True)`, la modalité de référence étant supprimée pour éviter la colinéarité parfaite. Ce même encodage est réutilisé pour le calcul du VIF/GVIF (Section 4.4.4). Pour le *Random Forest* en Python (`sklearn.ensemble.RandomForestClassifier`), qui ne gère pas non plus nativement

les facteurs, la même matrice encodée est utilisée, garantissant la comparabilité stricte des jeux de variables entre les trois modèles.

Intégration des pondérations d'enquête dans *XGBoost* Les pondérations d'échantillonnage sont intégrées via l'argument `weight` du constructeur `xgboost.DMatrix()` (API Python), qui permet d'attribuer à chaque observation son poids d'enquête lors du calcul de la fonction de perte [15]. Ce poids d'enquête ω_i est combiné multiplicativement avec le poids de rééquilibrage de classe `scale_pos_weight` : le poids final utilisé dans le calcul des gradients g_i et h_i pour chaque observation est $\omega_i^{\text{final}} = \omega_i \times \text{scale_pos_weight}^{Y_i}$, garantissant simultanément la représentativité vis-à-vis de la population béninoise et la correction du déséquilibre de classes.

Importance des variables *XGBoost* fournit trois mesures classiques [15] :

Gain : Réduction moyenne de la fonction de perte $\mathcal{L}$ apportée par les divisions sur X_j . **Métrique la plus pertinente pour l'interprétation classique.**

Cover : Nombre moyen d'observations couvertes par les divisions sur X_j (mesure de représentativité).

Frequency : Nombre de fois où X_j est utilisée dans les divisions (mesure de fréquence d'utilisation).

Ces mesures classiques sont complétées par les valeurs SHAP, plus rigoureuses et non biaisées, décrites dans la sous-section suivante.

4.6 Validation croisée par grappes

Une validation croisée K -fold standard qui coupe aléatoirement les observations viole l'indépendance des observations au sein des grappes du plan de sondage de l'AGVSAN 2017, pouvant conduire à une surestimation des performances des modèles [64]. Nous adoptons en conséquence une **validation croisée K -fold par grappes** : les plis ($K = 10$) sont constitués de grappes entières plutôt que d'observations individuelles, de sorte qu'aucune grappe ne soit scindée entre apprentissage et validation au sein d'un même pli. Cette procédure est implémentée nativement et simplement en Python via `sklearn.model_selection.GroupKFold(n_splits=10)`, en passant l'identifiant de grappe comme argument `groups` lors de l'appel à `.split()` — l'identifiant de grappe joue exactement le rôle attendu par cette fonction, ce qui rend cette implémentation plus directe que la construction manuelle équivalente sous R.

1. Les grappes de l'échantillon d'apprentissage sont réparties aléatoirement en $K = 10$ groupes de grappes de taille approximativement égale.

2. À chaque itération k , toutes les observations appartenant aux grappes du pli k sont retirées de l'échantillon d'apprentissage et utilisées comme ensemble de validation ; le modèle est entraîné sur les grappes des $K - 1$ plis restants.
3. Les métriques (AUROC, *Recall*, *F1-score*, Brier Score) sont moyennées sur les K plis.

Cette procédure garantit que les observations d'une même grappe ne se retrouvent jamais simultanément dans les ensembles d'apprentissage et de validation, produisant une estimation hors-échantillon non biaisée par la corrélation intra-grappe [64].

4.7 Interprétabilité des modèles : valeurs SHAP

4.7.1 Principe et calcul des valeurs SHAP

Pour chacun des trois modèles, les valeurs SHAP (*SHapley Additive exPlanations*) [47] sont calculées selon la formule de la revue de littérature (équation (1)). En pratique :

Pour *Random Forest* et *XGBoost* : L'algorithme TREE SHAP [46] permet un calcul exact en temps polynomial $\mathcal{O}(TLD^2)$, où T est le nombre d'arbres, L le nombre de feuilles et D la profondeur maximale.

Pour le Logit : L'algorithme LINEAR SHAP calcule les valeurs exactes en $\mathcal{O}(MP)$, où M est le nombre d'observations et P le nombre de prédicteurs.

Ces mesures corrigent les biais documentés par Strobl et al. [72] sur les importances classiques MDA et MDG, et permettent une comparaison directe entre les trois modèles.

4.7.2 Visualisations SHAP produites

Quatre types de visualisations via la bibliothèque `shap` [47] :

Summary plot : Importance globale de chaque variable (moyenne des valeurs SHAP absolues) et direction de son effet (rouge = augmente le risque, bleu = réduit le risque). Répond à l'OS1 dans une perspective complémentaire au Logit.

Dependence plot : Valeur SHAP en fonction de la valeur de la variable pour les variables les plus importantes, révélant les non-linéarités et interactions.

Waterfall plot : Décomposition de la prédiction pour un ménage individuel représentatif (ménage médian, ménage très vulnérable, ménage non vulnérable). Directement utilisable dans l'outil web (OS4).

Force plot : Visualisation interactive de la contribution de chaque variable pour un ménage donné, intégrable dans l'application web.

4.8 Évaluation, calibration et comparaison des modèles

4.8.1 Métriques de performance

Tous les modèles sont évalués sur le même échantillon test à partir de la matrice de confusion :

TABLE 12 – Matrice de confusion : classes prédites versus classes réelles

	Classe prédite	
	Insécurité ($\hat{Y} = 1$)	Sécurité ($\hat{Y} = 0$)
Classe réelle	Insécurité ($Y = 1$) Vrai Positif (VP) Faux Négatif (FN) Sécurité ($Y = 0$) Faux Positif (FP) Vrai Négatif (VN)	

Accuracy = $(VP + VN)/(VP + VN + FP + FN)$. Proportion globale de ménages correctement classifiés. *Limite* : peu informative si les classes sont déséquilibrées.

Precision (Valeur Prédictive Positive) = $VP/(VP + FP)$. Parmi les ménages ciblés comme à risque, quelle proportion l'est réellement ?

Recall (Sensibilité) — métrique stratégiquement prioritaire = $VP/(VP + FN)$. Parmi tous les ménages réellement en insécurité alimentaire, quelle proportion le modèle identifie-t-il ? Un Faux Négatif (ménage vulnérable non détecté) a un coût social asymétriquement supérieur à celui d'un Faux Positif [43].

F1-score = $2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$. Moyenne harmonique de la Precision et du Recall.

AUROC – Aire sous la courbe ROC

$$\text{auroc} = \int_0^1 \text{Recall}(\text{FPR}) d(\text{FPR}) \quad (20)$$

Une AUROC = 1 indique une discrimination parfaite; AUROC = 0,5 est équivalent à une classification aléatoire. Le calcul de l'AUROC et le tracé de la courbe ROC s'appuient sur `sklearn.metrics.roc_auc_score()` et `sklearn.metrics.roc_curve()`. La significativité statistique des différences d'AUROC entre modèles est testée via le test de DeLong et al. [20] : en l'absence de package Python aussi largement diffusé que `pROC` sous R [65], l'algorithme de calcul rapide de la variance de l'AUROC par la méthode des *U*-statistiques (Sun et Xu [73]) est implémenté directement (fonction `delong_roc_test()` codée sur la base de `numpy` et `scipy.stats`, largement documentée dans la littérature méthodologique associée à `pROC`).

Intervalle de confiance de l'AUROC : Au-delà du test de comparaison deux à deux (DeLong), un intervalle de confiance à 95 % est systématiquement rapporté pour

l'AUC de chaque modèle pris individuellement, calculé à partir de la variance de l'estimateur fournie par le même algorithme de DeLong (Section 4.5.3) :

$$IC_{95\%}(auroc) = auroc \pm 1,96\sqrt{\widehat{\text{Var}}(auroc)} \quad (21)$$

Cet intervalle est rapporté systématiquement à côté de chaque valeur ponctuelle d'AUC dans les tableaux de résultats (Section 5), de même que l'ensemble des p -valeurs associées aux tests de comparaison (test de DeLong entre modèles, test de Hosmer-Lemeshow, test de rapport de vraisemblance du Logit), afin de garantir une lecture inférentielle complète et non une seule lecture ponctuelle des estimateurs.

Brier Score

$$BS = \frac{1}{n} \sum_{i=1}^n (\hat{P}(Y_i = 1) - Y_i)^2 \quad (22)$$

Mesure conjointement la discrimination et la calibration des probabilités prédites. $BS = 0$: prédictions parfaites ; $BS = 0,25$: prédiction aléatoire pour un problème équilibré. Complète l'AUC pour une évaluation complète.

4.8.2 Évaluation de la calibration

La calibration des probabilités prédites est évaluée pour les trois modèles via :

Courbes de calibration (*reliability diagrams*) : Les observations sont groupées en déciles de probabilité prédite via `sklearn.calibration.calibration_curve(n_bins=10)`. Pour chaque groupe, la fréquence observée d'insécurité alimentaire est comparée à la probabilité prédite moyenne. Un modèle parfaitement calibré produit des points alignés sur la diagonale.

Test de Hosmer-Lemeshow : Appliqué aux trois modèles (pas seulement au Logit) pour une comparaison directe de la calibration entre approches, via la fonction codée manuellement décrite en Section 4.5.3.

Recalibration si nécessaire : Si les algorithmes ML présentent des probabilités mal calibrées — compression vers 0,5 pour le *Random Forest* conformément aux résultats de Niculescu-Mizil et Caruana [54] — une calibration post-hoc par régression isotonique [80], via `sklearn.calibration.CalibratedClassifierCV(method="isotonic", cv="prefit")`, sera appliquée avant la cartographie et le déploiement dans l'outil web. Le Brier Score est calculé via `sklearn.metrics.brier_score_loss()`.

4.8.3 Critères de sélection du meilleur modèle

Critère primaire : AUC maximale sur l'échantillon test.

Critère secondaire : Dans le contexte humanitaire, maximisation du *Recall* sous contrainte d'une AUC compétitive (différence non significative au test de DeLong,

$\alpha = 5\%$) et d'un *F1-score* acceptable.

Critère tertiaire : Brier Score minimal, garantissant des probabilités bien calibrées pour la cartographie et l'outil web.

4.9 Cartographie prédictive du risque d'insécurité alimentaire

4.9.1 Probabilités individuelles prédites

Le meilleur modèle sélectionné produit une probabilité individuelle d'insécurité alimentaire $\hat{P}(Y_i = 1|\mathbf{x}_i)$ pour chaque ménage i de la base complète. Ces probabilités constituent la matière première de la cartographie.

4.9.2 Agrégation spatiale pondérée à l'échelle communale

Les identifiants géographiques disponibles dans le questionnaire (0.1.3 Département, 0.1.4 Commune, 0.1.5 Arrondissement) permettent l'agrégation des probabilités individuelles à l'échelle communale. La probabilité moyenne pondérée prédite dans la commune u est :

$$\bar{P}_u = \frac{\sum_{i \in I_u} \omega_i \hat{P}(Y_i = 1|\mathbf{x}_i)}{\sum_{i \in I_u} \omega_i} \quad (23)$$

où I_u est l'ensemble des ménages enquêtés dans la commune u et ω_i le poids d'enquête du ménage i . L'utilisation des poids garantit la représentativité des estimations communales vis-à-vis de la population de référence. *Précaution méthodologique* : pour les communes faiblement échantillonnées (peu de ménages enquêtés dans I_u), l'estimateur $\bar{P}_u$ est sujet à une forte variance d'échantillonnage. Un estimateur de type *small area estimation* (lissage bayésien empirique vers la moyenne départementale) sera envisagé comme alternative de robustesse pour ces communes, à la suite des approches proposées par Jean et al. [40] et Pokhriyal et Jacques [61].

4.9.3 Test d'autocorrélation spatiale (indice de Moran)

Avant la cartographie, l'autocorrélation spatiale des probabilités communales prédites est testée via l'indice de Moran [53] (équation (3) de la revue de littérature) :

H_0 : Les probabilités prédites sont distribuées aléatoirement dans l'espace (absence d'autocorrélation spatiale).

Règle : $p < 0,05$ et $I > 0$: autocorrélation spatiale positive significative, confirmant l'hypothèse H_3 .

Implémentation : Matrice de contiguïté spatiale construite via `libpysal.weights.Queen.from_da` et indice calculé via `esda.Moran()`, du projet PYSAL [63], équivalent Python de

référence au package `spdep` [9].

4.9.4 Discrétisation du risque et cartographie choroplèthe

Les valeurs $\bar{P}_u$ sont catégorisées en quatre classes de risque (*Faible*, *Modéré*, *Élevé*, *Très élevé*) par la méthode des seuils naturels de Jenks [41], implémentée via `mapclassify.NaturalBreaks(k=4)`, qui minimise la variance intra-classe $\sum_u (\bar{P}_u - \bar{P}_{c(u)})^2$ tout en maximisant la variance inter-classes, produisant des seuils adaptés à la distribution empirique des données. La carte choroplèthe est produite sous Python en joignant les probabilités moyennes aux couches géographiques des communes béninoises (fichiers *shapefile* de l'IGN Bénin) via `geopandas` [42] — équivalent Python du package `sf` [57] — et visualisée avec `geopandas.GeoDataFrame.plot()` couplé à `matplotlib` pour la version statique du rapport, et avec `folium` pour la version interactive intégrée à l'outil web (OS4), ce dernier permettant un zoom, une infobulle par commune et une superposition directe des prédictions individuelles. La carte sera accompagnée d'une légende qualitative, d'une échelle graphique, d'une flèche Nord et d'un titre informatif, en conformité avec les standards cartographiques.

4.10 Logiciels et packages utilisés

L'ensemble des analyses statistiques, prédictives et cartographiques sera réalisé sous le langage open source Python (version 3.11) [76], dans un environnement Jupyter/JupyterLab pour l'exploration et le prototypage, puis consolidé en scripts modulaires pour la version finale du pipeline. Les principaux packages utilisés sont listés ci-dessous avec leur rôle spécifique dans l'analyse :

pandas / numpy Manipulation, nettoyage et structuration des données tabulaires ; calcul vectoriel [33, 52].

scipy.stats Tests statistiques non pondérés (Kolmogorov-Smirnov, χ^2 , t de Student, Mann-Whitney, Levene).

statsmodels Estimation du modèle Logit par maximum de vraisemblance (GLM, famille `Binomial`), inférence classique (erreurs-types, p -valeurs, intervalles de confiance, AIC), test de Box-Tidwell implémenté manuellement, calcul du VIF (`variance_inflation_factor`), correction de comparaisons multiples (`multipletests`) [66].

samplics Prise en compte du plan de sondage complexe (poids, strates, grappes) dans les statistiques descriptives et les tests bivariés pondérés (Section 4.4.3).

scikit-learn Régularisation Elastic-Net (`LogisticRegressionCV`), *Random Forest* (`RandomForestClassifier`), partition stratifiée (`train_test_split`), validation croisée par grappes (`GroupKFold`), *grid/random search* (`GridSearchCV`,

RandomizedSearchCV), imputation (SimpleImputer, KNNImputer), calibration (calibration_curve, CalibratedClassifierCV), métriques (AUROC, Brier Score, matrice de confusion) [58].

imbalanced-learn Application de la technique SMOTE pour la gestion du déséquilibre de classes [14, 44].

xgboost Entraînement des modèles *XGBoost* (API native `xgboost.train`, `DMatrix`) avec arrêt précoce et pondérations [15].

shap Calcul des valeurs SHAP (`TreeExplainer`, `LinearExplainer`) et visualisations (*summary plot*, *dependence plot*, *waterfall plot*, *force plot*) [47].

libpysal / **esda** Construction de la matrice de contiguïté spatiale et calcul de l'indice de Moran [63].

geopandas Manipulation et jointure des données géospatiales vectorielles [42].

mapclassify Discrétisation du risque par la méthode des seuils naturels de Jenks [41].

folium / **matplotlib** / **seaborn** Cartographie thématique choroplèthe interactive et statique, visualisations graphiques (distributions, importances des variables, courbes ROC) [38].

4.10.1 Reproductibilité logicielle

Afin de garantir la reproductibilité intégrale du pipeline analytique, l'environnement de calcul est figé et documenté via un fichier `environment.yml` (conda) ou `requirements.txt` (pip) précisant la version exacte de chaque package utilisé. Conformément à la Section 4.5.1, une graine aléatoire unique (`RANDOM_STATE = 42`) est fixée et propagée à l'ensemble des fonctions stochastiques du pipeline (partition, SMOTE, *Random Forest*, *XGBoost*, validation croisée, *random search*). Le code source (scripts et/ou *notebooks* Jupyter) sera rendu disponible en annexe ou via un dépôt versionné, afin de permettre la réplique complète des résultats présentés dans ce mémoire.

4.11 Considérations éthiques

La présente étude repose exclusivement sur l'exploitation secondaire de données déjà collectées, anonymisées et mises à disposition par le PAM et l'INSAE dans le cadre de l'enquête AGVSAN 2017 [62]. La collecte primaire de ces données a suivi les procédures éthiques standard des enquêtes ménages du PAM (consentement éclairé des répondants, anonymisation des identifiants personnels avant mise à disposition, protocole d'enquête validé par les autorités statistiques nationales). Aucune donnée directement identifiante (nom, contact, coordonnées GPS précises du ménage) n'étant présente dans la base transmise pour la présente recherche, et aucune nouvelle collecte de données auprès de sujets humains n'étant réalisée, ce travail relève d'une réutilisation secondaire

de données anonymisées ne nécessitant pas de nouvel avis éthique spécifique. Une vigilance particulière est néanmoins maintenue quant à l'usage des résultats produits : les probabilités individuelles prédites et leur agrégation cartographique (OS3, OS4) sont destinées exclusivement au ciblage programmatique des interventions humanitaires et de politique publique, et non à une identification ou une stigmatisation de ménages ou de communautés spécifiques.

Références bibliographiques

- [1] S. ALKIRE, U. KANAGARATNAM et N. SUPPA. *The Global Multidimensional Poverty Index (MPI) 2020*. OPHI Research Brief. Oxford Poverty et Human Development Initiative (OPHI), 2020. URL : <https://ophi.org.uk/multidimensional-poverty-index/>.
- [2] B. P. J. ANDRÉE, J. CHAMBERLIN, D. KRAYBILL, A. DE LA FUENTE et M. SCHIAVONE. « Predicting Food Crises Using News Streams ». In : 9449 (2020). DOI : [10.1596/1813-9450-9449](https://doi.org/10.1596/1813-9450-9449).
- [3] A. AZONHIHO, P. ADÉGBOLA et K. SOUROU. « Vulnérabilité alimentaire et facteurs déterminants au Bénin ». In : *Revue Africaine de Développement Rural* 7.2 (2020), p. 45-62.
- [4] R. O. BABATUNDE et M. QAIM. « Impact of Off-Farm Income on Food Security and Nutrition in Nigeria ». In : *Food Policy* 35.4 (2010), p. 303-311. DOI : [10.1016/j.foodpol.2010.01.006](https://doi.org/10.1016/j.foodpol.2010.01.006).
- [5] C. B. BARRETT et M. R. CARTER. « Failing Markets, Failing Governments : How Both Contribute to Persistent Poverty Traps ». In : *World Development* 139 (2021), p. 105255. DOI : [10.1016/j.worlddev.2020.105255](https://doi.org/10.1016/j.worlddev.2020.105255).
- [6] T. BENSON, N. MINOT, J. PENDER, M. ROBLES et J. VON BRAUN. *Information for Decision Making and Targeting : New Geographic Analysis of Poverty and Food Security in Africa*. Washington, D.C. : International Food Policy Research Institute (IFPRI), 2005.
- [7] J. BERGSTRA et Y. BENGIO. « Random Search for Hyper-Parameter Optimization ». In : *Journal of Machine Learning Research* 13.10 (2012), p. 281-305. URL : <https://jmlr.org/papers/v13/bergstra12a.html>.
- [8] A. BIRHANE, A. HAILESLASSIE, G. GEBRESAMUEL, M. HAILE et K. GEBREHIWOT. « Land Degradation and Food Insecurity in Drought-Prone Areas of Northern Ethiopia ». In : *Land Degradation & Development* 33.9 (2022), p. 1512-1526. DOI : [10.1002/ldr.4253](https://doi.org/10.1002/ldr.4253).
- [9] R. S. BIVAND, E. PEBESMA et V. GÓMEZ-RUBIO. *Applied Spatial Data Analysis with R*. 2nd. New York : Springer, 2013. DOI : [10.1007/978-1-4614-7618-4](https://doi.org/10.1007/978-1-4614-7618-4).
- [10] L. BREIMAN. « Random Forests ». In : *Machine Learning* 45.1 (2001), p. 5-32. DOI : [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [11] G. W. BRIER. « Verification of Forecasts Expressed in Terms of Probability ». In : *Monthly Weather Review* 78.1 (1950), p. 1-3. DOI : [10.1175/1520-0493\(1950\)078<0001:VOFEIT>2.0.CO;2](https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2).
- [12] C. BROWNE, D. S. MATTESON, L. MCBRIDE, L. HU, Y. LIU, W. SUN, U. NEHREN et C. B. BARRETT. « Multivariate Random Forest Prediction of Poverty and Malnutrition Prevalence ». In : *PLOS ONE* 16.9 (2021), e0255519. DOI : [10.1371/journal.pone.0255519](https://doi.org/10.1371/journal.pone.0255519).

- [13] C. CARLETTO, A. ZEZZA et R. BANERJEE. « Towards Better Measurement of Household Food Security : Harmonizing Indicators and the Role of Household Surveys ». In : *Global Food Security* 2.1 (2013), p. 28-35. DOI : [10.1016/j.gfs.2012.11.006](https://doi.org/10.1016/j.gfs.2012.11.006).
- [14] N. V. CHAWLA, K. W. BOWYER, L. O. HALL et W. P. KEGELMEYER. « SMOTE : Synthetic Minority Over-Sampling Technique ». In : *Journal of Artificial Intelligence Research* 16 (2002), p. 321-357. DOI : [10.1613/jair.953](https://doi.org/10.1613/jair.953).
- [15] T. CHEN et C. GUESTRIN. « XGBoost : A Scalable Tree Boosting System ». In : *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, p. 785-794. DOI : [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [16] J. COATES. « Build It Back Better : Deconstructing Food Security for Improved Measurement and Action ». In : *Global Food Security* 2.3 (2013), p. 188-194. DOI : [10.1016/j.gfs.2013.05.002](https://doi.org/10.1016/j.gfs.2013.05.002).
- [17] J. COATES, A. SWINDALE et P. BILINSKY. *Household Food Insecurity Access Scale (HFIAS) for Measurement of Food Access : Indicator Guide*. Rapp. tech. Washington, DC : Food et Nutrition Technical Assistance Project (FANTA), 2007. URL : <https://www.fantaproject.org/monitoring-and-evaluation/%20household-food-insecurity-access-scale-hfias>.
- [18] W. G. COCHRAN. *Sampling Techniques*. 3^e éd. New York : John Wiley & Sons, 1977.
- [19] A. DEATON et C. PAXSON. « Economies of Scale, Household Size, and the Demand for Food ». In : *Journal of Political Economy* 106.5 (1998), p. 897-930. DOI : [10.1086/250035](https://doi.org/10.1086/250035).
- [20] E. R. DELONG, D. M. DELONG et D. L. CLARKE-PEARSON. « Comparing the Areas Under Two or More Correlated Receiver Operating Characteristic Curves : A Nonparametric Approach ». In : *Biometrics* 44.3 (1988), p. 837-845. DOI : [10.2307/2531595](https://doi.org/10.2307/2531595).
- [21] DEPARTMENT FOR INTERNATIONAL DEVELOPMENT. *Sustainable Livelihoods Guidance Sheets*. London : DFID, 1999. URL : <https://www.livelihoodscentre.org/documents/114097690/%20114438878/Sustainable+livelihoods+guidance+sheets.pdf>.
- [22] C. DOSS. « Intrahousehold Bargaining and Resource Allocation in Developing Countries ». In : *The World Bank Research Observer* 28.1 (2013), p. 52-78. DOI : [10.1093/wbro/lkt001](https://doi.org/10.1093/wbro/lkt001).
- [23] M. FAFCHAMPS et S. LUND. « Risk-Sharing Networks in Rural Philippines ». In : *Journal of Development Economics* 71.2 (2004), p. 261-287. DOI : [10.1016/S0304-3878\(03\)00029-4](https://doi.org/10.1016/S0304-3878(03)00029-4).
- [24] S. T. FELEKE, R. L. KILMER et C. H. GLADWIN. « Determinants of Food Security in Southern Ethiopia at the Household Level ». In : *Agricultural Economics* 33.3 (2005), p. 351-363. DOI : [10.1111/j.1574-0864.2005.00072.x](https://doi.org/10.1111/j.1574-0864.2005.00072.x).
- [25] FOOD AND AGRICULTURE ORGANIZATION OF THE UNITED NATIONS. *Food Security*. Policy Brief 2. Rome : FAO, 2006. URL : https://www.fao.org/fileadmin/templates/faoitally/%20documents/pdf/pdf_Food_Security_Cocept_Note.pdf.

- [26] FOOD AND AGRICULTURE ORGANIZATION OF THE UNITED NATIONS. *The State of Food and Agriculture 2022 : Leveraging Automation in Agriculture for Transformation of Agri-Food Systems*. Rome : FAO, 2022. DOI : [10.4060/cb9479en](https://doi.org/10.4060/cb9479en).
- [27] FOOD AND AGRICULTURE ORGANIZATION OF THE UNITED NATIONS, IFAD, UNICEF, WFP et WHO. *The State of Food Security and Nutrition in the World 2021*. Rome : FAO, 2021. DOI : [10.4060/cb4474en](https://doi.org/10.4060/cb4474en).
- [28] FOOD AND AGRICULTURE ORGANIZATION OF THE UNITED NATIONS, IFAD, UNICEF, WFP et WHO. *The State of Food Security and Nutrition in the World 2023*. Rome : FAO, 2023. DOI : [10.4060/cc3017en](https://doi.org/10.4060/cc3017en).
- [29] J. FOX et G. MONETTE. « Generalized Collinearity Diagnostics ». In : *Journal of the American Statistical Association* 87.417 (1992), p. 178-183. DOI : [10.1080/01621459.1992.10475190](https://doi.org/10.1080/01621459.1992.10475190).
- [30] J. H. FRIEDMAN. « Greedy Function Approximation : A Gradient Boosting Machine ». In : *The Annals of Statistics* 29.5 (2001), p. 1189-1232. DOI : [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451).
- [31] L. HADDAD, C. HAWKES, P. WEBB, S. THOMAS, J. NEGIN, D. HEADEY et L. SMITH. « A New Global Research Agenda for Food ». In : *Nature* 540.7631 (2016), p. 30-32. DOI : [10.1038/540030a](https://doi.org/10.1038/540030a).
- [32] F. E. HARRELL. *Regression Modeling Strategies : With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis*. 2^e éd. New York : Springer, 2015. DOI : [10.1007/978-3-319-19425-7](https://doi.org/10.1007/978-3-319-19425-7).
- [33] C. R. HARRIS, K. J. MILLMAN, S. J. VAN DER WALT, R. GOMMERS, P. VIRTANEN, D. COUNAPEAU et al. « Array Programming with NumPy ». In : *Nature* 585.7825 (2020), p. 357-362. DOI : [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2).
- [34] T. HASTIE, R. TIBSHIRANI et J. FRIEDMAN. *The Elements of Statistical Learning : Data Mining, Inference, and Prediction*. 2^e éd. New York : Springer, 2009. DOI : [10.1007/978-0-387-84858-7](https://doi.org/10.1007/978-0-387-84858-7).
- [35] D. HEADEY et O. ECKER. « Rethinking the Measurement of Food Security : From First Principles to Best Practice ». In : *Food Security* 5.3 (2013), p. 327-343. DOI : [10.1007/s12571-013-0253-0](https://doi.org/10.1007/s12571-013-0253-0).
- [36] J. HODDINOTT et Y. YOHANNES. *Dietary Diversity as a Food Security Indicator*. FCND Discussion Paper 136. Washington, DC : International Food Policy Research Institute (IFPRI), 2002. URL : <https://www.ifpri.org/publication/%20dietary-diversity-food-security-indicator>.
- [37] D. W. HOSMER, S. LEMESHOW et R. X. STURDIVANT. *Applied Logistic Regression*. 3^e éd. Hoboken, NJ : Wiley, 2013. DOI : [10.1002/9781118548387](https://doi.org/10.1002/9781118548387).
- [38] J. D. HUNTER. « Matplotlib : A 2D Graphics Environment ». In : *Computing in Science & Engineering* 9.3 (2007), p. 90-95. DOI : [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).
- [39] INSTITUT NATIONAL DE LA STATISTIQUE ET DE L'ANALYSE ÉCONOMIQUE. *Enquête Harmonisée sur les Conditions de Vie des Ménages au Bénin (EHCVM) 2018–2019*. Cotonou, Bénin : INSAE, 2019.

- [40] N. JEAN, M. BURKE, M. XIE, W. M. DAVIS, D. B. LOBELL et S. ERMON. « Combining Satellite Imagery and Machine Learning to Predict Poverty ». In : *Science* 353.6301 (2016), p. 790-794. DOI : [10.1126/science.aaf7894](https://doi.org/10.1126/science.aaf7894).
- [41] G. F. JENKS. « The Data Model Concept in Statistical Mapping ». In : *International Yearbook of Cartography* 7 (1967), p. 186-190.
- [42] K. JORDAHL, J. VAN DEN BOSSCHE, M. FLEISCHMANN, J. WASSERMAN, J. MCBRIDE, J. GERARD et al. « GeoPandas : Python Tools for Geographic Data ». In : Software, version 0.8.1. 2020. URL : <https://geopandas.org>.
- [43] J. KLEINBERG, H. LAKKARAJU, J. LESKOVEC, J. LUDWIG et S. MULLAINATHAN. « Human Decisions and Machine Predictions ». In : *The Quarterly Journal of Economics* 133.1 (2018), p. 237-293. DOI : [10.1093/qje/qjx032](https://doi.org/10.1093/qje/qjx032).
- [44] G. LEMAÎTRE, F. NOGUEIRA et C. K. ARIDAS. « Imbalanced-learn : A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning ». In : *Journal of Machine Learning Research* 18.17 (2017), p. 1-5.
- [45] T. LUMLEY et A. SCOTT. « Fitting Regression Models to Survey Data ». In : *Statistical Science* 32.2 (2017), p. 265-278. DOI : [10.1214/16-STS605](https://doi.org/10.1214/16-STS605).
- [46] S. M. LUNDBERG, G. ERION, H. CHEN, A. DEGRAVE, J. M. PRUTKIN, B. NAIR, R. KATZ, J. HIMMELFARB, N. BANSAL et S.-I. LEE. « From Local Explanations to Global Understanding with Explainable AI for Trees ». In : *Nature Machine Intelligence* 2.1 (2020), p. 56-67. DOI : [10.1038/s42256-019-0138-9](https://doi.org/10.1038/s42256-019-0138-9).
- [47] S. M. LUNDBERG et S.-I. LEE. « A Unified Approach to Interpreting Model Predictions ». In : *Advances in Neural Information Processing Systems*. T. 30. Curran Associates, Inc., 2017, p. 4765-4774. URL : <https://proceedings.neurips.cc/paper/2017/hash/%208a20a8621978632d76c43dfd28b67767-Abstract.html>.
- [48] D. MAXWELL, R. CALDWELL et M. LANGWORTHY. « Measuring Food Insecurity : Can an Indicator Based on Localized Coping Behaviors Be Used to Compare Across Contexts ? ». In : *Food Policy* 33.6 (2008), p. 533-540. DOI : [10.1016/j.foodpol.2008.02.004](https://doi.org/10.1016/j.foodpol.2008.02.004).
- [49] D. MAXWELL, B. VAITLA et J. COATES. « How Do Indicators of Household Food Insecurity Measure Up? An Empirical Comparison from Ethiopia ». In : *Food Policy* 47 (2014), p. 107-116. DOI : [10.1016/j.foodpol.2014.04.003](https://doi.org/10.1016/j.foodpol.2014.04.003).
- [50] S. MAXWELL et T. FRANKENBERGER. *Household Food Security : Concepts, Indicators, Measurements. A Technical Review*. New York/Rome : UNICEF/IFAD, 1992.
- [51] P. MCCULLAGH et J. A. NELDER. *Generalized Linear Models*. 2^e éd. London : Chapman et Hall/CRC, 1989. DOI : [10.1007/978-1-4899-3242-6](https://doi.org/10.1007/978-1-4899-3242-6).
- [52] W. MCKINNEY. « Data Structures for Statistical Computing in Python ». In : *Proceedings of the 9th Python in Science Conference*. 2010, p. 56-61. DOI : [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a).
- [53] P. A. P. MORAN. « Notes on Continuous Stochastic Phenomena ». In : *Biometrika* 37.1-2 (1950), p. 17-23. DOI : [10.2307/2332142](https://doi.org/10.2307/2332142).

- [54] A. NICULESCU-MIZIL et R. CARUANA. « Predicting Good Probabilities with Supervised Learning ». In : *Proceedings of the 22nd International Conference on Machine Learning (ICML)*. 2005, p. 625-632. DOI : [10.1145/1102351.1102430](https://doi.org/10.1145/1102351.1102430).
- [55] A. I. OGUNNIYI, S. O. OMOTOSO, K. K. SALMAN, A. O. OMOTAYO, K. O. OLAGUNJU et A. O. AREMU. « Socio-Economic Drivers of Food Insecurity Among Rural Households in Nigeria : Evidence from Southern and Northern Nigeria ». In : *Social Sciences* 9.8 (2020), p. 139. DOI : [10.3390/socsci9080139](https://doi.org/10.3390/socsci9080139).
- [56] T. O. OJO et L. J. S. BAIYEGUNHI. « Determinants of Food Security and Its Transition Among Smallholder Farming Households in South-West Nigeria : Endogenous Switching Regression Approach ». In : *World Development* 138 (2021), p. 105251. DOI : [10.1016/j.worlddev.2020.105251](https://doi.org/10.1016/j.worlddev.2020.105251).
- [57] E. J. PEBESMA. « Simple Features for R : Standardized Support for Spatial Vector Data ». In : *The R Journal* 10.1 (2018), p. 439-446. DOI : [10.32614/RJ-2018-009](https://doi.org/10.32614/RJ-2018-009).
- [58] F. PEDREGOSA, G. VAROQUAUX, A. GRAMFORT, V. MICHEL, B. THIRION, O. GRISEL et al. « Scikit-learn : Machine Learning in Python ». In : *Journal of Machine Learning Research* 12 (2011), p. 2825-2830.
- [59] P. PINSTRUP-ANDERSEN. « Food Security : Definition and Measurement ». In : *Food Security* 1.1 (2009), p. 5-7. DOI : [10.1007/s12571-008-0002-y](https://doi.org/10.1007/s12571-008-0002-y).
- [60] J. C. PLATT. « Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods ». In : *Advances in Large Margin Classifiers*. Sous la dir. d'A. J. SMOLA, P. BARTLETT, B. SCHÖLKOPF et D. SCHUURMANS. Cambridge, MA : MIT Press, 1999, p. 61-74.
- [61] N. POKHRIYAL et D. C. JACQUES. « Combining Disparate Data Sources for Improved Poverty Prediction and Mapping ». In : *Proceedings of the National Academy of Sciences* 114.46 (2017), E9783-E9792. DOI : [10.1073/pnas.1700319114](https://doi.org/10.1073/pnas.1700319114).
- [62] PROGRAMME ALIMENTAIRE MONDIAL. *Analyse Globale de la Vulnérabilité, de la Sécurité Alimentaire et de la Nutrition (AGVSAN) du Bénin*. Cotonou : PAM/INSAE, 2017.
- [63] S. J. REY et L. ANSELIN. « PySAL : A Python Library of Spatial Analytical Methods ». In : *Handbook of Applied Spatial Analysis* (2010), p. 175-193. DOI : [10.1007/978-3-642-03647-7_11](https://doi.org/10.1007/978-3-642-03647-7_11).
- [64] D. R. ROBERTS, V. BAHN, S. CIUTI, M. S. BOYCE, J. ELITH, G. GUILLERA-ARROITA, S. HAUENSTEIN, J. J. LAHOZ-MONFORT, B. SCHRÖDER, W. THUILLER, D. I. WARTON, B. A. WINTLE, F. HARTIG et C. F. DORMANN. « Cross-Validation Strategies for Data with Temporal, Spatial, Hierarchical, or Phylogenetic Structure ». In : *Ecography* 40.8 (2017), p. 913-929. DOI : [10.1111/ecog.02881](https://doi.org/10.1111/ecog.02881).
- [65] X. ROBIN, N. TURCK, A. HAINARD, N. TIBERTI, F. LISACEK, J.-C. SANCHEZ et M. MÜLLER. « pROC : An Open-Source Package for R and S+ to Analyze and Compare ROC Curves ». In : *BMC Bioinformatics* 12 (2011), p. 77. DOI : [10.1186/1471-2105-12-77](https://doi.org/10.1186/1471-2105-12-77).

- [66] S. SEABOLD et J. PERKTOLD. « statsmodels : Econometric and Statistical Modeling with Python ». In : *Proceedings of the 9th Python in Science Conference*. 2010, p. 92-96. DOI : [10.25080/Majora-92bf1922-011](https://doi.org/10.25080/Majora-92bf1922-011).
- [67] A. SEN. *Poverty and Famines : An Essay on Entitlement and Deprivation*. Oxford : Oxford University Press, 1981.
- [68] L. S. SHAPLEY. « A Value for n -Person Games ». In : *Contributions to the Theory of Games*. Sous la dir. de H. W. KUHN et A. W. TUCKER. T. 2. Princeton, NJ : Princeton University Press, 1953, p. 307-317.
- [69] G. SHMUELI. « To Explain or to Predict ? » In : *Statistical Science* 25.3 (2010), p. 289-310. DOI : [10.1214/10-STS330](https://doi.org/10.1214/10-STS330).
- [70] L. C. SMITH et L. HADDAD. *Explaining Child Malnutrition in Developing Countries : A Cross-Country Analysis*. IFPRI Research Report 111. Washington, D.C. : International Food Policy Research Institute (IFPRI), 2000.
- [71] E. W. STEYERBERG, A. J. VICKERS, N. R. COOK, T. GERDS, M. GONEN, N. OBUCHOWSKI, M. J. PENCINA et M. W. KATTAN. « Assessing the Performance of Prediction Models : A Framework for Traditional and Novel Measures ». In : *Epidemiology* 21.1 (2010), p. 128-138. DOI : [10.1097/EDE.0b013e3181c30fb2](https://doi.org/10.1097/EDE.0b013e3181c30fb2).
- [72] C. STROBL, A.-L. BOULESTEIX, A. ZEILEIS et T. HOTHORN. « Bias in Random Forest Variable Importance Measures : Illustrations, Sources and a Solution ». In : *BMC Bioinformatics* 8.1 (2007), p. 25. DOI : [10.1186/1471-2105-8-25](https://doi.org/10.1186/1471-2105-8-25).
- [73] X. SUN et W. XU. « Fast Implementation of DeLong’s Algorithm for Comparing the Areas Under Correlated Receiver Operating Characteristic Curves ». In : *IEEE Signal Processing Letters* 21.11 (2014), p. 1389-1393. DOI : [10.1109/LSP.2014.2337313](https://doi.org/10.1109/LSP.2014.2337313).
- [74] A. SWINDALE et P. BILINSKY. *Household Dietary Diversity Score (HDDS) for Measurement of Household Food Access : Indicator Guide*. Rapp. tech. Washington, DC : Food et Nutrition Technical Assistance Project (FANTA), 2006. URL : <https://www.fantaproject.org/monitoring-and-evaluation/%20household-dietary-diversity-score-hdds>.
- [75] UNITED NATIONS CHILDREN’S FUND. *The State of the World’s Children 2021 : On My Mind – Promoting, Protecting and Caring for Children’s Mental Health*. New York : UNICEF, 2021. URL : <https://www.unicef.org/reports/%20state-worlds-children-2021>.
- [76] G. VAN ROSSUM et F. L. DRAKE. *Python 3 Reference Manual*. Scotts Valley, CA : CreateSpace, 2009.
- [77] WORLD BANK GROUP. *Poverty and Shared Prosperity 2022 : Correcting Course*. Washington, D.C. : World Bank, 2022. DOI : [10.1596/978-1-4648-1893-6](https://doi.org/10.1596/978-1-4648-1893-6).
- [78] WORLD FOOD PROGRAMME. *Food Consumption Score Nutritional Quality Analysis (FCS-N) Guidelines*. Rome : WFP, 2008. URL : https://documents.wfp.org/stellent/groups/public/%20documents/manual_guide_proced/wfp197216.pdf.
- [79] WORLD FOOD PROGRAMME. *Consolidated Approach for Reporting Indicators of Food Security (CARI) Guidelines*. Rapp. tech. Rome : World Food Programme, 2012. URL :

<https://www.wfp.org/publications/%20consolidated-approach-reporting-indicators-food-%20security-cari-guidelines>.

- [80] B. ZADROZNY et C. ELKAN. « Transforming Classifier Scores into Accurate Multiclass Probability Estimates ». In : *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2002, p. 694-699. DOI : [10.1145/775047.775151](https://doi.org/10.1145/775047.775151).